

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH



BÁO CÁO ĐỒ ÁN CHUYÊN NGÀNH

MÔ HÌNH THỊ GIÁC - NGÔN NGỮ CHO BÀI TOÁN NHẬN DIỆN BIỂU THỨC TOÁN HỌC VIẾT TAY

Ngành: KHOA HỌC MÁY TÍNH

HỘI ĐỒNG: 17L - ĐỒ ÁN CHUYÊN NGÀNH
CHỦ TỊCH HỘI ĐỒNG: PGS. TS. Lê Hồng Trang
THƯ KÝ HỘI ĐỒNG: CN. Nguyễn Thành Lộc
ỦY VIÊN HỘI ĐỒNG: CN. Trần Nguyễn Minh Duy

GVHD: TS. Nguyễn Đức Dũng

SVTH1: Lưu Lê Gia Bảo - 2210220
SVTH2: Hoa Toàn Hạc - 2210917

THÀNH PHỐ HỒ CHÍ MINH, THÁNG 1 - 2025



Ngày: _____

TS. Nguyễn Đức Dũng (Giảng viên hướng dẫn)

Tiến sĩ

Khoa Khoa học và Kỹ thuật Máy tính



Lời cam đoan

Nhóm tác giả xin cam đoan nghiên cứu này là công trình tự thân của nhóm, được thực hiện dưới sự hướng dẫn và giám sát của TS. Nguyễn Đức Dũng. Các kết quả trong nghiên cứu này là kết quả thực nghiệm và chưa từng công bố dưới bất kỳ hình thức nào trước đây. Tất cả các tài liệu được sử dụng trong quá nghiên cứu đều do nhóm tác giả tự thu thập và tìm hiểu từ nhiều nguồn khác nhau, và được trích dẫn đầy đủ trong phần **Tài liệu tham khảo**.

Ngoài ra, nghiên cứu này có sử dụng các kết quả của một số (nhóm) tác giả và công trình nghiên cứu khác, tất cả đều đã được ghi nhận và trích dẫn hợp lệ.

Trong trường hợp xảy ra bất kỳ hành vi sao chép nào, nhóm tác giả hoàn toàn chịu trách nhiệm về hành động của mình. Trường Đại học Bách Khoa - Đại học Quốc gia Thành phố Hồ Chí Minh không chịu trách nhiệm đối với bất kỳ vi phạm bản quyền nào phát sinh từ nghiên cứu này.

TP. Hồ Chí Minh, tháng 12, năm 2024

Sinh viên thực hiện

Lưu Lê Gia Bảo

Hoa Toàn Hạc

Lời cảm ơn

Trước hết, nhóm tác giả xin bày tỏ lòng biết ơn chân thành đến TS. Nguyễn Đức Dũng. Nhóm tác giả trân trọng cảm ơn thầy đã dành thời gian quý báu để hướng dẫn, định hướng và động viên nhóm tác giả trong suốt quá trình lập đề cương và triển khai Đồ án chuyên ngành này.

Tiếp theo, nhóm tác giả xin gửi lời cảm ơn sâu sắc đến các giảng viên thuộc Khoa Khoa học và Kỹ thuật Máy tính, Trường Đại học Bách Khoa - Đại học Quốc gia Thành phố Hồ Chí Minh. Các giảng viên là những người đã trang bị cho nhóm tác giả nền tảng kiến thức vững chắc. Đây chính là bàn đạp quan trọng để nhóm thực hiện báo cáo này và cũng là tiền đề để thực hiện Đồ án Tốt nghiệp trong thời gian sắp tới.

Cuối cùng, nhóm tác giả xin cảm ơn gia đình đã luôn ủng hộ nhóm tác giả trong suốt hành trình đại học. Sự hy sinh của cha mẹ chính là nguồn động lực lớn nhất để nhóm tác giả nỗ lực học tập và rèn luyện. Bên cạnh đó, nhóm tác giả cũng biết ơn các anh chị, bạn bè trong quá trình học tập và làm việc, những người đã cùng đồng hành và tận tình hướng dẫn, trao đổi kiến thức với nhóm tác giả trong môi trường chuyên nghiệp. Chính những trải nghiệm thực tiễn này đã góp phần không nhỏ trong quá trình định hình tư duy và hành vi của nhóm tác giả theo chiều hướng tốt hơn.

Tóm tắt

Nhận diện biểu thức Toán học viết tay (Handwritten Mathematical Expression Recognition - HMER) là một trong những bài toán thách thức trong lĩnh vực thị giác máy tính hiện nay. Khác với quá trình nhận dạng văn bản thông thường (Optical Character Recognition - OCR) với các ký tự được sắp xếp tuyến tính, sự đa dạng trong cách viết ký hiệu của mỗi người, sự nhập nhằng giữa các ký tự có hình dạng tương tự nhau cũng như mối quan hệ giữa các ký tự với nhau như chỉ số trên (superscript), chỉ số dưới (subscript), phân số (fraction), căn thức (square root), ... khiến cho HMER cần được nghiên cứu chuyên biệt hơn. Đề án này tập trung vào việc khai thác kiến trúc mô hình Encoder-Decoder kết hợp với cơ chế **Attention** cũng như học đa nhiệm **Multitask Learning** để đề xuất một pipeline dự đoán chuỗi $\text{L}^{\text{A}}\text{T}_{\text{E}}\text{X}$ của một biểu thức Toán học từ ảnh đầu vào.

Các nhiệm vụ chính bao gồm: nghiên cứu cơ sở lý thuyết về mô hình Encoder-Decoder và các cơ chế **Attention**; khảo sát và đánh giá các phương pháp tiếp cận bài toán hiện có, và triển khai pipeline [35] trên bộ dữ liệu CROHME [31]. Cụ thể, pipeline này bổ sung một tác vụ hỗ trợ mới, là dự đoán sự phân bố vị trí trong không gian của các ký hiệu của các ảnh biểu thức viết tay. Kết quả ban đầu cho thấy pipeline này giúp tăng khả năng nhận diện ký tự và cấu trúc cho các mô hình HMER, đặc biệt đối với các biểu thức dài và phức tạp. Đồng thời tác vụ hỗ trợ mới cho thấy hiệu quả khi so sánh với các tác vụ hỗ trợ đã được đề xuất trước đó.

Báo cáo đã thiết lập nền tảng cho giai đoạn nghiên cứu tiếp theo của Đề án Tốt nghiệp, bao gồm việc mở rộng tập dữ liệu huấn luyện và kiểm thử như HME100K [34] hay MathWriting [8], cũng như kết hợp các tác vụ hỗ trợ khác cho mô hình và tối ưu hóa các thành phần của mô hình để đạt hiệu suất cao hơn. Những cải tiến này hứa hẹn sẽ nâng cao hiệu suất và độ tin cậy của mô hình, đặc biệt trong quá trình học tập và làm việc với các văn bản Toán học nói riêng và Khoa học nói chung.

Từ khóa: Nhận diện biểu thức Toán học viết tay, Encoder-Decoder, Attention, Học đa nhiệm, Bản đồ phân phối Gaussian hai chiều.

Contents

1	Giới thiệu	11
1.1	Đặt vấn đề	11
1.2	Mục tiêu	12
1.3	Phạm vi đề tài	13
1.4	Cấu trúc bài báo cáo	13
2	Các công trình nghiên cứu liên quan	15
2.1	Grammar-Based methods	15
2.2	Encoder-Decoder Based Methods	16
2.2.1	RNN-based Models	16
2.2.2	Transformer-based Models	18
2.3	Tree-based Decoding Methods	19
2.4	Một số phương pháp khác	20
2.5	Bàn luận, đánh giá	22
3	Cơ sở lý thuyết	23
3.1	Coverage Attention trong RNN	23
3.2	Multi-head Attention	23
3.3	CNN Encoder	24
3.4	Positional Encoding	24
4	Thí nghiệm ban đầu và phân tích thất bại	26
4.1	Động cơ và giả thuyết ban đầu	26
4.2	Thí nghiệm 1: Tiếp cận end-to-end HMER với VLM	26
4.2.1	Thiết lập thí nghiệm	27
4.2.2	Kết quả và Quan sát	27
4.3	Thí nghiệm 2: Bổ sung giám sát cấu trúc và pipeline hai giai đoạn	27
4.3.1	Cải tiến phương pháp	28
4.3.2	Kết quả thực nghiệm	28
4.4	Phân tích nguyên nhân và bài học rút ra	28
4.4.1	Hạn chế về quy mô dữ liệu	28
4.4.2	Sự lệch pha về không gian đặc trưng	29



4.5	Điều chỉnh và nỗ lực khắc phục	29
4.6	Tổng kết và định hướng giải pháp	29
4.7	Thí nghiệm 3: Encoder-Decoder với Transformer thuần và tác động của học đa nhiệm	30
4.7.1	Thiết lập mô hình	30
4.7.2	Các biến thể thí nghiệm	31
4.7.3	Kết quả định lượng	31
4.7.3.1	Hiệu năng cơ sở:	31
4.7.3.2	Tác động của học đa nhiệm:	31
4.7.3.3	Hạn chế của ràng buộc cú pháp:	32
4.7.4	Phân tích và thảo luận	32
4.7.5	Tổng kết và định hướng giải pháp	32
5	Giải pháp đề xuất	34
5.1	Định nghĩa vấn đề	34
5.1.1	Phát biểu bài toán HMER	34
5.1.2	Phân tích cơ chế Coverage trong CoMER và Hạn chế	34
5.2	Tổng quan giải pháp đề xuất	35
5.2.1	Khung học tập đa nhiệm (Multi-task Learning Framework)	36
5.2.2	Cơ chế Giải mã có hướng dẫn (Guided Decoding Mechanism)	37
5.2.3	Hàm mục tiêu tổng quát	38
5.2.4	Vai trò kép của Kiến trúc Đề xuất	38
5.3	Chi tiết giải pháp	39
5.3.1	Cách tạo ra ground truth cho hai nhiệm vụ phụ	39
5.3.1.1	Tổng quan về biểu diễn Ground Truth	39
5.3.1.2	Bản đồ phân bố không gian (Spatial Distribution Map)	40
5.3.1.3	Bản đồ quan hệ cấu trúc (Structural Relation Map)	40
5.3.1.4	Quy trình ánh xạ ngữ nghĩa sang không gian ảnh	41
5.3.2	Khôi phục Bản đồ Phân bố Không gian (Spatial Distribution Recovery)	43
5.3.2.1	Động cơ thiết kế	43
5.3.2.2	Định nghĩa Bản đồ Phân bố Không gian	44
5.3.2.3	Vai trò trong Học đa nhiệm và Biểu diễn đặc trưng	44
5.3.3	Dự đoán Quan hệ Cấu trúc (Structural Relation Prediction)	45

5.3.3.1	Động cơ thiết kế	45
5.3.3.2	Định nghĩa Bản đồ Quan hệ Cấu trúc	46
5.3.3.3	Vai trò: Bộ điều tiết Cấu trúc (Structural Regularizer)	46
5.3.3.4	Tác động đến khả năng hiểu biểu thức	47
5.3.4	Cơ chế Chú ý Bao phủ có Hướng dẫn (Guided Coverage Attention)	47
5.3.4.1	Hạn chế của Cơ chế Coverage thụ động trong CoMER	48
5.3.4.2	Nguyên lý hoạt động của Guided Coverage	48
5.3.4.3	Trực giác hoạt động và Lợi ích giải mã	49
5.3.4.4	Tổng kết tác động	50
5.3.5	Hàm mục tiêu và Chiến lược Huấn luyện Đa nhiệm	50
5.3.5.1	Hàm mục tiêu tổng quát	50
5.3.5.2	Phân tích vai trò các thành phần mất mát	51
5.3.5.3	Cơ chế cộng hưởng trong Huấn luyện Đa nhiệm	51
5.4	Dữ liệu đánh giá	52
5.4.1	Đặc tả dữ liệu	52
5.5	Metrics đánh giá	53
5.5.1	Expression Recognition Rate (ExpRate)	53
5.5.2	Tính nghiêm ngặt và sự phù hợp	54
5.6	Kết quả thí nghiệm	54
5.6.1	Kết quả định lượng	55
5.6.2	So sánh với paper CoMER	55
5.6.3	Nhận xét	55
6	Tổng kết	57
6.1	Đánh giá quá trình thực hiện Đồ án Chuyên ngành	57
6.2	Hướng phát triển và kế hoạch thực hiện giai đoạn Đồ án Tốt nghiệp	58
6.3	Hướng phát triển	58
6.4	Kế hoạch thực hiện giai đoạn Đồ án Tốt nghiệp	59



Danh mục viết tắt



Danh sách bảng

1	Tổng hợp các nghiên cứu ứng với từng phương pháp	21
2	Ưu và nhược điểm của các phương pháp	22
3	Kết quả thực nghiệm ban đầu với kiến trúc VLM End-to-End	27
4	Kết quả thực nghiệm của mô hình tái lập trên các tập dữ liệu CROHME.	55
5	So sánh ExpRate (0 lỗi) giữa mô hình thực nghiệm và kết quả gốc từ paper CoMER.	55
6	Dự kiến kế hoạch thực hiện Đồ án Tốt nghiệp.	59



Danh sách hình vẽ

1	Tổng quan kiến trúc SRSC	36
2	Kết quả spatial ground truth tạo được	40
3	Kết quả relation ground truth tạo được	43
4	Kiến trúc Guided ARM đề xuất	49
5	Validation loss của các nhiệm vụ bổ trợ	59

1 Giới thiệu

1.1 Đặt vấn đề

Với xu hướng chuyển đổi số đang diễn ra một cách mạnh mẽ trên toàn Thế giới, nhu cầu số hóa các tài liệu tri thức, đặc biệt là trong lĩnh vực Toán học nói riêng và Khoa học nói chung trở thành nhu cầu cấp thiết hơn bao giờ hết. Biểu thức Toán học đóng vai trò như một ngôn ngữ chung để mô tả các công thức, các mô hình Kinh tế và các thuật toán dành cho máy tính. Tuy nhiên, việc dẫn nhập các công thức Toán học vào máy tính thông qua các công cụ soạn thảo văn bản như Microsoft Word Equation hay sử dụng mã $\text{L}^{\text{A}}\text{T}_{\text{E}}\text{X}$ thường tốn nhiều thời gian, công sức và đòi hỏi người nhập cần có vốn kiến thức kết hợp kỹ năng nhất định về các ngôn ngữ để có thể tiến hành thao tác và nhập liệu một cách chính xác. Ngược lại, việc viết tay các công thức trên giấy, bảng trắng hoặc các thiết bị cảm ứng (điện thoại thông minh, máy tính bảng, bảng vẽ kỹ thuật số) lại là phương thức tự nhiên, nhanh chóng và trực quan nhất đối với con người.

Nhận diện biểu thức Toán học viết tay (Handwritten Mathematical Expression Recognition - HMER) ra đời như một yêu cầu tất yếu nối liền giữa phương thức nhập liệu của con người và khả năng xử lý, lưu trữ của máy tính. HMER hướng đến mục tiêu chuyển đổi hình ảnh các công thức Toán học viết tay thành dạng văn bản có cấu trúc (như $\text{L}^{\text{A}}\text{T}_{\text{E}}\text{X}$, MathML) hoàn chỉnh. Việc này giúp phát triển các ứng dụng cần thiết cho công việc giảng dạy trực tuyến, các hệ thống tự động chấm điểm, các nhu cầu về tìm kiếm các công thức cần thiết, ... Đặc biệt, trong khoảng thời gian đại dịch COVID-19 diễn ra, nhu cầu sử dụng các nền tảng trực tuyến cho việc dạy học và kiểm tra trực tuyến được tăng lên không ngừng, khiến cho nhu cầu về độ chính xác của việc nhận diện các biểu thức Toán học viết tay được đẩy lên cao, giúp nâng cao chất lượng đào tạo trong thời gian dịch bệnh và trong tương lai.

Tuy nhiên, không giống như các bài toán nhận diện chữ viết sử dụng phương pháp Nhận dạng ký tự quang học (Optical Character Recognition - OCR) thông thường, HMER đối diện với sự đa dạng trong mối quan hệ phức tạp về vị trí giữa các ký tự với nhau trong cùng biểu thức. Ví dụ, các biểu thức chứa phân số, căn thức và tích phân bao gồm không chỉ các ký tự đơn giản (các biến x, y, z ; các con số $1, \infty$) mà còn chứa các cấu trúc phức tạp về đóng mở ngoặc của biểu thức, các ký tự bị lồng vào nhau, các mối quan hệ về chỉ số trên (superscript), chỉ số dưới (subscript), ... Bên cạnh đó, sự nhập nhằng về cách viết các ký tự mà nguyên nhân chủ yếu đến từ phong cách viết của mỗi người cũng là một thách thức lớn. Ví dụ, các ký tự có

hình dạng tương tự nhau (số 0 và chữ O , số 1 và chữ I hoặc dấu gạch đứng $|$, số 2 và chữ z , chữ q và số 9) hay độ nghiêng, độ đậm nhạt của các ký tự cũng ảnh hưởng tới quá trình nhận dạng các ký tự có trong biểu thức. Những yếu tố này khiến cho việc nhận diện chính xác cả về ký tự lẫn cấu trúc của biểu thức trở thành một bài toán có tính thách thức cao, đòi hỏi các mô hình cần có khả năng trích xuất đặc trưng mạnh mẽ và suy luận được cấu trúc của biểu thức, đặc biệt khi độ dài và độ phức tạp của biểu thức tăng lên.

Các phương pháp tiếp cận hiện đại dựa trên học sâu (Deep Learning), đặc biệt là kiến trúc Encoder-Decoder với cơ chế **Attention** đã đạt được những bước tiến đáng kể trong HMER, vượt xa các phương pháp tiếp cận truyền thống dựa trên việc trích xuất các ký tự kết hợp với một bộ ngữ pháp được định nghĩa sẵn. Tuy nhiên, các mô hình này [39], [36], [14] vẫn bộc lộ các hạn chế trong quá trình nắm bắt thông tin về cấu trúc không gian giữa các ký tự có trong biểu thức, ảnh hưởng đáng kể tới quá trình giải mã các ký tự trong phần Decoder. Do đó, vấn đề đặt ra là cần có một cơ chế để có thể xử lý vấn đề này, từ đó giúp nâng cao tính ổn định và độ chính xác cho các mô hình HMER.

1.2 Mục tiêu

Mục tiêu của đề tài này là phát triển một mô hình dựa trên kiến trúc Encoder-Decoder, kết hợp với tác vụ bổ sung (auxiliary task) giúp dự đoán sự phân bố vị trí trong không gian (spatial distribution map) của các ký tự trong biểu thức có trong hình ảnh. Từ đây, mô hình có thể cung cấp chuỗi $\text{\LaTeX}$ đầu ra với độ chính xác cao với đầu vào là ảnh chụp một biểu thức Toán học viết tay với các mức độ phức tạp khác nhau.

Cụ thể, đề tài nhắm đến:

1. Tìm hiểu các mô hình dựa trên kiến trúc Encoder-Decoder được đề xuất trước đó và phân tích các ưu điểm cũng như nhược điểm của chúng.
2. Nghiên cứu và phát triển một pipeline nhận diện dựa trên kiến trúc Encoder-Decoder, tích hợp một tác vụ bổ sung giúp mô hình nắm được thông tin về vị trí của các ký tự có trong ảnh chính xác và hiệu quả hơn. Đề án đề xuất kết hợp hai thông tin: **Spatial-Field** là một không gian mô tả sự có mặt của ký tự có trong ảnh và **Spatial-Relation** là quan hệ về mặt cấu trúc giữa các ký tự với nhau. Mục tiêu của các đề xuất này là giúp mô hình không chỉ nhận dạng được chính xác các ký tự mà còn hiểu được cấu trúc của toàn bộ biểu thức.

3. Thực nghiệm và đánh giá mô hình trên bộ dữ liệu CROHME [31]. Sau đó, phân tích kết quả và so sánh hiệu quả với các mô hình khác và định hướng tối ưu hóa cho giai đoạn tiếp theo của Đồ án.

1.3 Phạm vi đề tài

Đồ án chuyên ngành sẽ tập trung vào các vấn đề chính như sau:

1. Nghiên cứu kiến trúc của các mô hình Encoder-Decoder, tập trung vào:
 - Cách trích xuất các đặc trưng có trong ảnh ở bước Encoder.
 - Cách giải mã và sinh chuỗi $\text{L}^{\text{A}}\text{T}_{\text{E}}\text{X}$ cho chuỗi đầu ra ở bước Decoder.
2. Tìm hiểu và đánh giá các cách tiếp cận về bài toán HMER:
 - Tìm hiểu các phương pháp cho bài toán HMER.
 - Đánh giá ưu điểm và nhược điểm của từng phương pháp.
3. Nghiên cứu một mô hình cơ sở từ các công trình liên quan để
 - Phân tích ưu điểm và hạn chế của mô hình cho bài toán HMER.
 - Thực hiện một ví dụ minh họa cho quá trình sinh chuỗi đầu ra.
4. Đề xuất hướng cải tiến cho giai đoạn Đồ án Tốt nghiệp
 - Phương pháp tích hợp tác vụ bổ sung khác vào mô hình.
 - Cải thiện độ chính xác của mô hình.

1.4 Cấu trúc bài báo cáo

Cấu trúc báo cáo gồm 5 chương chính

1. **Chương 1** cung cấp một cái nhìn tổng quan về vấn đề. Đồng thời, trình bày mục tiêu chính mà đồ án hướng đến và xác định rõ ràng phạm vi nghiên cứu, triển khai.
2. **Chương 2** tổng hợp các công trình nghiên cứu liên quan đến bài toán, được đưa ra bàn luận, đánh giá nhằm cung cấp cái nhìn sâu sắc hơn về các phương pháp hiện tại và những hạn chế của chúng.

3. **Chương 3** tập trung vào việc cung cấp những kiến thức cơ bản liên quan đến Encoder, Decoder làm nền tảng cho các nội dung được sử dụng trong đề án.
4. **Chương 4** minh họa quy trình sử dụng một mô hình cơ sở từ công trình liên quan đã chọn, kèm theo một ví dụ minh họa đơn giản, đồng thời đề xuất hướng phát triển trong tương lai nhằm cải thiện phương pháp hiệu quả hơn.
5. **Chương 5** tóm tắt và đánh giá toàn diện các kết quả đạt được trong quá trình thực hiện Đề án Chuyên ngành. Đồng thời, nêu rõ các khó khăn, thách thức gặp phải trong quá trình thực hiện cũng như các hạn chế và thiếu sót chưa được khắc phục. Từ đó, xây dựng kế hoạch cải thiện và định hướng phát triển tiếp theo cho giai đoạn thực hiện Đề án Tốt nghiệp.

2 Các công trình nghiên cứu liên quan

Sự phát triển của các mô hình phục vụ cho bài toán HMER có thể chia thành hai giai đoạn chính: Giai đoạn của các phương pháp truyền thống dựa trên một bộ ngữ pháp được định nghĩa sẵn và giai đoạn ứng dụng các phương pháp học sâu (Deep Learning). Phần này của báo cáo sẽ đi phân tích các phương pháp này, xuất phát từ các mô hình phân tích cấu trúc thủ công đến các kiến trúc Encoder-Decoder sau này tích hợp cơ chế **Attention** và học đa nhiệm.

2.1 Grammar-Based methods

HMER đã được nghiên cứu trong nhiều thập kỷ [1] và có một số phương pháp đã được đề xuất [22]. Dưới đây là các đóng góp nổi bật của các nghiên cứu dựa trên phương pháp sử dụng các văn phạm tự định nghĩa.

Cách tiếp cận cổ điển đối với bài toán HMER là chia nhỏ bài toán thành hai giai đoạn theo thứ tự: nhận diện các ký tự và phân tích cấu trúc của các biểu thức [4]. Nghiên cứu đầu tiên của H.Anderson [1] đã đưa ra một đề xuất tiếp cận bài toán thông qua phương pháp nhận dạng các cú pháp có hướng (syntax-directed recognition). Cụ thể, tác giả sử dụng các quy tắc ngữ pháp được tọa độ hóa (coordinate grammar) để phân tích mối quan hệ trong không gian hai chiều giữa các ký tự và xây dựng lại cấu trúc của biểu thức Toán học. Từ đây, các ngữ pháp khác được khám phá và ứng dụng vào cho bài toán. Ví dụ, nghiên cứu của Chan và Yeung [3] sử dụng bộ ngữ pháp mệnh đề được định nghĩa sẵn (Definite clause grammar - DCG) kết hợp với cơ chế phát hiện và sửa lỗi trong quá trình phân tích cú pháp. Mô hình của Laviotte và Pottier [13] được xây dựng dựa trên ngữ pháp đồ thị (graph grammars), với việc các biểu thức Toán học được biểu diễn dưới dạng một đồ thị với các đỉnh là ký hiệu và các cạnh biểu thị quan hệ giữa chúng, sau đó sử dụng ngữ pháp đồ thị phụ thuộc ngữ cảnh (context-sensitive graph grammar) kết hợp với cơ chế viết lại đồ thị (graph rewriting) tiến hành phân tích theo hướng từ dưới lên (bottom-up), trong đó các quy tắc ngữ pháp được áp dụng để liên tục rút gọn các đồ thị con thành các nút có ngữ nghĩa, đồng thời sử dụng thông tin ngữ cảnh để giải quyết các trường hợp nhập nhằng trong cấu trúc hai chiều của biểu thức. Nghiên cứu của Yamamoto và các cộng sự [33] đã đề xuất quá trình viết biểu thức Toán học như một quá trình sinh các nét dựa trên văn phạm phi ngữ cảnh có tính xác suất (Probabilistic Context-Free Grammars - PCFG). Thay vì giải quyết tuần tự từng bước như thông thường, phương pháp này thực hiện đồng thời ba thao tác bao gồm phân đoạn (segmentation), nhận dạng ký tự và phân tích

cấu trúc trong một khuôn khổ xác suất, từ đó tìm ra biểu thức có khả năng đúng cao nhất. MacLean và Labahn đã xây dựng một cách tiếp cận sử dụng văn phạm quan hệ (relational grammars) và tập mờ (fuzzy set) [20] để mô hình hóa sự không chắc chắn trong các mối quan hệ không gian giữa các ký tự với nhau. Thông qua quá trình gán các giá trị phụ thuộc cho các quan hệ và sử dụng thuật toán phân tích cú pháp để tìm ra cây cấu trúc có tổng độ tin cậy cao nhất, vấn đề nhập nhằng về các ký tự có thể được giải quyết một cách hiệu quả.

Nhằm giải quyết các hạn chế của phương pháp tuần tự, các nghiên cứu sau đó đã đưa ra các đề xuất dựa trên PCFG, sử dụng một mô hình xác suất để phân tích cấu trúc của biểu thức cũng như hạn chế tối đa sự nhập nhằng về mặt ký hiệu. Álvaro và Sanchez [45] đã đề xuất một hệ thống cho phép phân tích cấu trúc của các biểu thức bằng việc sử dụng một bộ văn phạm phi ngữ cảnh ngẫu nhiên (Stochastic context-free grammars). Đây được xem như là một cách tiếp cận tổng quan vì có thể kết hợp các thông tin thu được khác nhau để xác định biểu thức gần giống nhất so với biểu thức trong ảnh đầu vào. Biến thể của thuật toán Cocke-Younger-Kasami (CYK) [33] đã được Yamamoto và các cộng sự giới thiệu cho bước phân tích PCFG trong không gian hai chiều. MacLean và Labahn [21] đề xuất một mô hình dựa trên mạng Bayes; hệ thống xây dựng một "rừng phân tích" (parse forest) chứa tất cả các cách diễn giải có thể chấp nhận được của các nét viết thông qua một bộ ngữ pháp quan hệ, sau đó sử dụng hàm Bayes để chọn ra cấu trúc tối ưu nhất.

Mặc dù vậy, các phương pháp này thường có độ phức tạp tính toán rất cao, và đặc biệt là phụ thuộc quá nhiều vào các bộ ngữ pháp được định nghĩa thủ công, khiến chúng kém linh hoạt và khó mở rộng trên các bộ dữ liệu lớn.

2.2 Encoder-Decoder Based Methods

Trong các năm gần đây, kiến trúc Encoder-Decoder đã cho thấy được hiệu năng cao trong nhiều tác vụ sinh chuỗi đầu ra từ ảnh ban đầu (**image-to-text**), như nhận diện văn bản có trong ảnh (scene text recognition) [6] hay thêm mô tả cho ảnh (image captioning) [32]. Sau đây là một số phương pháp sử dụng kiến trúc Encoder-Decoder đã được nghiên cứu và đề xuất.

2.2.1 RNN-based Models

Nghiên cứu mang tính đột phá và mở đầu cho việc sử dụng kiến trúc Encoder-Decoder là WAP [39] và cho thấy kết quả vượt trội hơn rõ rệt so với các phương pháp sử dụng bộ ngữ pháp được định nghĩa sẵn trong cuộc thi CROHME vào năm 2014 [23]. WAP sử dụng một mạng

tích chập đầy đủ (Fully Convolutional Network - FCN) chỉ chứa các lớp tích chập, pooling và các hàm kích hoạt (activation layers) cho quá trình encoder, ánh xạ ảnh ban đầu sang dạng biểu diễn trung gian là một lưới các đặc trưng trong không gian hai chiều ("**Watch**"). Decoder sử dụng một mạng nơ-ron nối tiếp có cổng (Gated Recurrent Units - GRU) nhận đầu ra của encoder và sinh ra chuỗi $\text{L}^{\text{A}}\text{T}_{\text{E}}\text{X}$ tương ứng. Bên cạnh đó, decoder cũng được kết hợp cơ chế **Attention**. Cơ chế này cho phép decoder tập trung vào các vùng cụ thể của ảnh đầu vào có liên quan đến ký tự đang được dự đoán ("**Attend**") và sinh ra ký tự $\text{L}^{\text{A}}\text{T}_{\text{E}}\text{X}$ tương ứng ("**Parse**"). WAP đã chứng minh khả năng vượt trội trong việc xử lý các kiểu chữ viết tay khác nhau mà không cần phân cách rõ các ký tự một cách tường minh.

Một vấn đề được đặt ra trong HMER là sự khác nhau về kích thước giữa các ký tự. Các ký tự như dấu chấm, dấu phẩy có kích thước rất nhỏ khi so sánh với các ký tự như dấu tích phân hay phân số, và dễ bị mất thông tin khi đi qua các lớp pooling của CNN. Để khắc phục điều này, Zhang và các cộng sự [36] đã đề xuất DenseWAP. Mô hình này thay thế encoder của WAP sử dụng VGG [25] bằng DenseNet (Densely Connected Convolutional Networks) [11] với khả năng tái sử dụng các đặc trưng đã được trích xuất ở các bước trước đó. Đồng thời, DenseWAP cũng đề xuất một cơ chế mới mang tên **Multi-scale Attention** cho phép mô hình tổng hợp các đặc trưng ở độ phân giải khác nhau giúp nắm bắt đồng thời chi tiết cục bộ (cho các ký tự nhỏ) và chi tiết toàn cục với các ký tự lớn.

Một cách tiếp cận khác của bài toán được đề xuất bởi Wu và các cộng sự là PAL-v2 (Paired Adversarial Learning) [30]. Mô hình này đề xuất một phương pháp giúp các đặc trưng bất biến về mặt ngữ nghĩa (semantic-invariant features) được trích xuất và học. Trong quá trình huấn luyện, mô hình nhận đầu vào là ảnh viết tay kèm với các **printed templates** tương ứng. Bộ phân biệt (discriminator) được tích hợp giúp chỉ dẫn bộ nhận dạng (recognizer) trích xuất các đặc trưng sao cho biểu diễn của chữ viết tay tương đồng với biểu diễn chuẩn của các **printed templates**. Bên cạnh đó, RNN-based encoder ở các mô hình trước đó được thay thế bằng convolutional decoder, hạn chế hiện tượng vanishing gradient thường xuyên xuất hiện trong RNN và tăng khả năng bao phủ (coverage) trong quá trình giải mã thông tin sau bước encoder.

Nghiên cứu của Li và các cộng sự [15] đã đề xuất một mô hình mới là **Counting-Aware Network** (CAN) [15]. Nhóm tác giả nhận thấy rằng các mô hình encoder-decoder trước đó gặp khó khăn trong quá trình xử lý với các công thức có cấu trúc phức tạp hoặc có độ dài lớn, dẫn đến việc dự đoán thiếu hoặc thừa ký tự. Nhằm giải quyết vấn đề này, CAN tích hợp thêm một tác vụ phụ trợ là đếm ký tự (symbol counting) được tối ưu hóa đồng thời với tác vụ chính

của mô hình. Mô hình đề xuất **Multi-Scale Counting Module - MSCM**, sử dụng các lớp tích chập với kích thước kernel khác nhau để trích xuất đặc trưng và dự đoán số lượng của từng loại ký tự có trong ảnh mà không cần label vị trí cụ thể. Vector lưu trữ số lượng này được đưa vào bộ giải mã **Counting-Combined Attentional Decoder - CCAD**, kết hợp với vector đặc trưng được trích xuất từ ảnh ban đầu để tính chỉnh trọng số của bước **Attention**, giúp mô hình nhận biết rõ ràng hơn về sự hiện diện của các ký tự, từ đó giảm sai sót và nâng cao độ chính xác so với các mô hình trước đó.

2.2.2 Transformer-based Models

Sự hạn chế của RNN trong việc xử lý các phụ thuộc dài (long-term dependencies) và khả năng huấn luyện song song đã thúc đẩy việc áp dụng kiến trúc Transformer [28] vào bài toán.

Zhao và các cộng sự là những người đầu tiên áp dụng Transformer vào bài toán HMER với mô hình **Bidirectionally Trained Transformer - BTTR** [42]. BTTR sử dụng DenseNet để trích xuất các đặc trưng hình ảnh, sau đó qua bộ giải mã Transformer để sinh ra chuỗi $L^A_T E_X$. Khác với các phương pháp trước đây chỉ giải mã theo một chiều từ trái sang phải (left-to-right, L2R), nhóm tác giả đề xuất một cách huấn luyện mới theo hai chiều bằng cách sử dụng hai decoder hoạt động song song với nhau: một decoder theo chiều thuận (L2R) và một theo chiều nghịch (right-to-left, R2L). Phương pháp này cho phép mô hình nắm được các quan hệ phụ thuộc nằm xa nhau giữa các ký tự Toán học, đồng thời khắc phục vấn đề **lack of coverage** thường gặp ở RNN. Các thực nghiệm trên bộ dữ liệu CROHME cho thấy BTTR cải thiện đáng kể độ chính xác với các biểu thức dài và phức tạp so với các mô hình sử dụng RNN.

Mô hình **Converge Modeling for Transformer-based HMER** được đề xuất bởi Zhao và các cộng sự [41] đã giải quyết được vấn đề thiếu hụt cơ chế **coverage** trong các bộ decoder được hiện thực bằng Transformer. Với hai cơ chế **self-coverage** và **cross-coverage** được kết hợp với nhau, đi kèm với **Attention Refinement Module - ARM** được thiết kế để tích hợp thông tin bao phủ vào quá trình tính toán attention mà vẫn giữ được tính song song của mô hình Transformer, kết quả thực nghiệm trên bộ dữ liệu CROHME cho thấy CoMER đạt hiệu quả tối ưu hơn 3.6% so với mô hình cơ sở BTTR.

Dựa trên nền tảng của các mô hình CoMER và CAN, Zhang và các cộng sự đã phát triển mô hình **General Category Network - GCN** [40] nhằm giải quyết vấn đề về sự nhập nhằng trong cách viết của các ký tự. GCN tích hợp **General Category Recognition Task - GCRT** là một tác vụ phụ trợ giúp phân loại các ký hiệu Toán học vào các nhóm lớn (nhóm chữ số

$\{0, 1, 2, \dots, 9\}$, nhóm chữ cái $\{a, b, \dots, z, A, B, \dots, Z\}$, nhóm toán tử $\{+, -, \times, \div, \dots\}$, nhóm các ký hiệu Hy Lạp $\{\alpha, \beta, \gamma, \dots\}$, ...) và được tối ưu hóa đồng thời với hàm mất mát chính của mô hình. GCRT giúp mô hình có thể biết được loại ký tự có khả năng xuất hiện tại vị trí đang xét nếu có sự không rõ ràng trong cách viết ký hiệu đó so với các ký hiệu khác.

Bên cạnh đó, các **ký tự ẩn** (implicit characters) xuất hiện trong chuỗi L^AT_EX đích có vai trò quyết định cấu trúc của biểu thức nhưng không có sự tương ứng trực tiếp với các ký tự có trong ảnh đầu vào. Zhu và các cộng sự đã đề xuất mô hình **ICAL** [43] để giải quyết vấn đề này. Mô-đun **ICCM - Implicit Character Construction Module** được xây dựng riêng biệt và được huấn luyện để dự đoán sự phân bố và vị trí của các ký tự ẩn dựa trên cấu trúc của toàn bộ biểu thức bằng cách phân tích mối quan hệ về mặt không gian và ngữ pháp giữa các ký tự hiện có. Kết quả thu được từ ICCM được hợp nhất (fusion) với kết quả của decoder. ICAL cho ra kết quả tốt trên cả hai tập dữ liệu phổ biến là HME100K (69.06%) và CROHME (tăng độ chính xác trong khoảng 1.39% tới 2.25%).

2.3 Tree-based Decoding Methods

Song song với sự phát triển của các mô hình **sequence-to-sequence** sử dụng RNN và Transformer là decoder, các phương pháp giải mã dựa trên cây (Tree-based Decoding) ra đời nhằm khắc phục hạn chế về sự phức tạp của cấu trúc biểu thức bằng cách sử dụng cây cú pháp (syntax tree).

DenseWAP-TD [38] là công trình đầu tiên đưa khái niệm giải mã cây vào các mô hình HMER dựa trên học sâu. Mô hình này được xây dựng dựa trên nền tảng của DenseWAP với việc sử dụng DenseNet làm encoder và thay thế GRU-decoder bằng tree-structured decoder. DenseWAP-TD mô hình hóa quá trình sinh biểu thức như một quá trình xây dựng cây cú pháp top-down. Decoder lúc này có vai trò dự đoán mối quan hệ cha-con giữa các ký hiệu với nhau thông qua tập hợp các mối quan hệ cơ bản trong biểu thức. Tại mỗi bước giải mã, mô hình xét trạng thái của nút cha và trạng thái hiện tại của ảnh để sinh ra các nút con tương ứng với các mối quan hệ này. Quá trình bắt đầu từ nút gốc và dừng lại khi gặp các ký hiệu kết thúc ở tất cả các nhánh. Với khả năng bảo toàn cấu trúc tô-pô (topological structure) của biểu thức, kết quả thực nghiệm trên bộ dữ liệu CROHME 2014 cho thấy DenseWAP-TD vượt trội so với DenseWAP sử dụng cơ chế giải mã tuần tự. DenseWAP-TD cũng cho thấy sự vượt trội rõ rệt trên các biểu thức có độ sâu cấu trúc lớn.

Tiếp nối DenseWAP-TD, Wu và các cộng sự [29] đã đề xuất TDv2, với mục đích chính

là tối ưu hóa phương pháp giải mã dựa trên kiến trúc cây được hiện thực trong mô hình DenseWAP-TD. Nhằm giải quyết vấn đề một biểu thức có thể có nhiều cây cú pháp hợp lệ khác nhau, TDv2 cho mô hình tiếp thu nhiều phương pháp chuyển đổi cây khác nhau cho cùng một chuỗi $\text{L}^{\text{A}}\text{T}_{\text{E}}\text{X}$. Trong quá trình huấn luyện, mô hình được "tiếp xúc" với các biến thể cấu trúc cây tương đương nhau, giúp nó học được các đặc trưng cấu trúc bất biến.

Bên cạnh đó, Yuan và các cộng sự [34] đã giới thiệu SAN. Nhóm tác giả nhận thấy các mô hình cho bài toán HMER sinh ra các chuỗi vi phạm các quy tắc cơ bản của $\text{L}^{\text{A}}\text{T}_{\text{E}}\text{X}$, từ đó đưa ra đề xuất khắc phục điều này bằng cách chuyển đổi chuỗi $\text{L}^{\text{A}}\text{T}_{\text{E}}\text{X}$ thành một cây phân tích cú pháp tuân theo một bộ ngữ pháp được định nghĩa trước. Quá trình dự đoán chuỗi đầu ra trở thành bài toán duyệt cây cú pháp với ràng buộc về cú pháp và ngữ nghĩa tại từng bước decode. SAN cũng sử dụng mô-đun mới có tên SAAM, kết hợp trạng thái cú pháp hiện tại của biểu thức giúp mô hình "tập trung" vào đúng thành phần cấu trúc đang được giải mã.

2.4 Một số phương pháp khác

Liu và các cộng sự giới thiệu NAMER [19], đưa ra một hướng tiếp cận mới thông qua loại bỏ cơ chế giải mã tự hồi quy (autoregressive) có tốc độ chậm và khả năng tích lũy sai số khi qua các lớp. NAMER bao gồm hai thành phần chính là **Visual Aware Tokenizer** (VAT) và **Parallel Graph Decoder** (PGD). VAT thực hiện quá trình encode các ký hiệu và quan hệ giữa các ký tự với nhau. PGD thực hiện việc tinh chỉnh các token và thiết lập kết nối dựa trên ngữ cảnh thị giác và ngôn ngữ toàn cục. Phương pháp này cho thấy đạt được tốc độ nhanh hơn đáng kể và giúp giảm thiểu việc phân loại nhầm các ký hiệu nhập nhằng với nhau.

Một hướng tiếp cận khác là Uni-MuMER của Li và các cộng sự [17] đề xuất. Phương pháp này tập trung vào việc **fine-tuning** các mô hình ngôn ngữ - thị giác (VLM) đã được **pre-trained** cho HMER mà không làm thay đổi cấu trúc gốc của VLM. Để thêm các "kiến thức" của HMER vào VLM, Uni-MuMER thực hiện ba tác vụ hỗ trợ. Đầu tiên, **Tree-Aware Chain-of-Thought** (Tree-CoT) được thiết kế giúp mô hình suy luận cấu trúc không gian hai chiều theo trình tự logic (tương tự quá trình phân tích cây cú pháp), giúp giải quyết vấn đề về các thành phần của biểu thức lồng ghép vào nhau. Tiếp theo, **Error-Driven Learning** (EDL) giảm sự nhập nhằng giữa các ký tự có hình dáng tương đồng nhau thông qua quá trình "học" trực tiếp từ các lỗi sai thường gặp trong quá trình nhận diện các ký tự. Cuối cùng, **Symbol Counting** (SC) yêu cầu mô hình dự đoán chính xác số lượng ký hiệu hiện có nhằm hạn chế các lỗi dự đoán thừa hoặc thiếu các ký tự.

Các nghiên cứu trên được nhóm tác giả tổng hợp và trình bày trong bảng 1 dưới đây

Phương pháp	Mô hình	Cơ chế	Đóng góp
Grammar-Based Methods	Anderson [1]	Coordinate Grammar	Đề xuất tiếp cận nhận dạng cú pháp có hướng, phân tích quan hệ không gian 2D thông qua ngữ pháp tọa độ, đặt nền móng cho HMER.
	Chan & Yeung [3]	Definite Clause Grammar (DCG)	Sử dụng ngữ pháp mệnh đề định nghĩa sẵn kết hợp cơ chế phát hiện và sửa lỗi trong quá trình phân tích cú pháp để tăng độ chính xác.
	Lavirotte & Pottier [13]	Graph Grammar	Mô hình hóa biểu thức dưới dạng đồ thị, sử dụng ngữ pháp đồ thị phụ thuộc ngữ cảnh và cơ chế viết lại đồ thị (graph rewriting) từ dưới lên.
	Yamamoto et al. [33]	Probabilistic Context-Free Grammar (PCFG)	Đề xuất quy trình sinh nét dựa trên PCFG, thực hiện đồng thời phân đoạn, nhận dạng và phân tích cấu trúc trong khuôn khổ xác suất thống nhất.
	MacLean & Labahn [20]	Relational Grammar & Fuzzy Sets	Sử dụng tập mờ để mô hình hóa sự không chắc chắn trong quan hệ không gian; xây dựng "rừng phân tích" (parse forest) để tìm cấu trúc tối ưu nhất.
Encoder-Decoder Based (RNN)	WAP [39]	FCN + GRU + Attention	Tiên phong sử dụng kiến trúc Encoder-Decoder end-to-end; cơ chế "Watch, Attend, Parse" xử lý chữ viết tay không cần phân đoạn tường minh.
	DenseWAP [36]	DenseNet + Multi-scale Attention	Thay thế FCN bằng DenseNet để tái sử dụng đặc trưng; Multi-scale Attention giúp nắm bắt chi tiết ký tự nhỏ và cấu trúc toàn cục.
	PAL-v2 [30]	Adversarial Learning	Sử dụng học đối nghịch (Adversarial Learning) để trích xuất các đặc trưng bất biến về mặt ngữ nghĩa, tương đồng với printed templates.
	CAN [15]	Multi-Scale Counting Module (MSCM)	Tích hợp tác vụ đếm ký tự (symbol counting) để giải quyết vấn đề dự đoán thiếu hoặc thừa ký tự (under/over-parsing) trong các biểu thức dài.
Encoder-Decoder Based (Transformer)	BTTR [42]	Bidirectional Transformer	Áp dụng Transformer huấn luyện hai chiều (L2R và R2L) để nắm bắt các phụ thuộc xa và khắc phục hạn chế đơn hướng của RNN.
	CoMER [41]	Coverage Modeling + ARM	Giải quyết vấn đề thiếu hụt coverage trong Transformer bằng Attention Refinement Module (ARM) và cơ chế self/cross-coverage tích lũy.
	GCN [40]	General Category Recognition	Tích hợp tác vụ phân loại nhóm ký tự (GCRT) để giải quyết sự nhập nhằng giữa các ký tự có hình dạng tương đồng.
	ICAL [43]	Implicit Character Construction	Đề xuất mô-đun dự đoán ký tự ẩn (như cấu trúc không gian, dấu ngoặc) để hỗ trợ decoder quyết định cấu trúc $\text{\LaTeX}$ chính xác hơn.
Tree-Based Decoding Methods	DenseWAP-TD [38]	Tree-structured Decoder	Thay thế giải mã tuần tự bằng giải mã cây (top-down), dự đoán quan hệ cha-con để bảo toàn cấu trúc tô-pô của biểu thức.
	TDv2 [29]	Optimized Tree Decoder	Tối ưu hóa giải mã cây bằng cách cho phép mô hình học nhiều biến thể cây cú pháp tương đương nhau, tăng tính linh hoạt.
	SAN [34]	Syntax-Aware Network	Chuyển đổi chuỗi $\text{\LaTeX}$ thành cây cú pháp tuân theo ngữ pháp định nghĩa trước, kết hợp trạng thái cú pháp vào quá trình giải mã để đảm bảo tính hợp lệ.
Other Methods	NAMER [19]	Non-autoregressive Decoding	Loại bỏ cơ chế tự hồi quy để tăng tốc độ suy diễn; sử dụng Parallel Graph Decoder để tinh chỉnh token dựa trên ngữ cảnh toàn cục.
	Uni-MuMER [17]	Vision-Language Model (VLM)	Fine-tuning các mô hình VLM lớn cho HMER thông qua các tác vụ hỗ trợ như Tree-CoT và Error-Driven Learning, tận dụng tri thức pre-trained.

Bảng 1: Tổng hợp các nghiên cứu ứng với từng phương pháp

2.5 Bàn luận, đánh giá

Thông qua tổng hợp trên, nhóm tác giả có một số nhận xét về ưu cũng như nhược điểm được tổng kết qua bảng sau

Phương pháp	Ưu điểm	Nhược điểm
Grammar-Based Methods	- Cấu trúc rõ ràng, dễ diễn giải (interpretable) và minh bạch về logic. - Có khả năng kiểm soát chặt chẽ tính đúng đắn của cú pháp đầu ra. - Hiệu quả với các tập dữ liệu nhỏ hoặc các bài toán có quy tắc cố định, ít biến thể.	- Độ phức tạp tính toán rất cao, đặc biệt với không gian tìm kiếm lớn (NP-hard trong nhiều trường hợp). - Phụ thuộc nhiều vào các bộ ngữ pháp định nghĩa thủ công, kém linh hoạt và khó bảo trì. - Khó mở rộng và thích nghi với các phong cách viết tay đa dạng và nhiều thực tế.
RNN-based Encoder-Decoder	- Khả năng học end-to-end từ ảnh sang chuỗi LaTeX mà không cần thiết kế đặc trưng thủ công. - Xử lý tốt các biến thể chữ viết tay nhờ cơ chế Attention mềm dẻo. - Cơ chế Coverage tự nhiên của RNN giúp theo dõi trạng thái giải mã tốt hơn Transformer gốc.	- Hạn chế trong việc xử lý các phụ thuộc dài (long-term dependencies) do vấn đề quên lãng. - Tốc độ huấn luyện chậm do tính chất tuần tự của RNN, khó song song hóa. - Hiện tượng vanishing gradient ảnh hưởng đến hiệu suất trên biểu thức rất dài và phức tạp.
Transformer-based Encoder-Decoder	- Khả năng huấn luyện song song, tốc độ cao hơn RNN, tận dụng tốt phần cứng GPU. - Nắm bắt tốt các mối quan hệ phụ thuộc xa toàn cục nhờ cơ chế Self-Attention. - Hiệu suất vượt trội trên các tập dữ liệu lớn và biểu thức phức tạp về cấu trúc.	- Thiếu cơ chế Coverage tự nhiên, dễ dẫn đến lỗi lặp hoặc thiếu ký tự (under/over-parsing) nếu không có module bổ trợ (như CoMER). - Đòi hỏi lượng dữ liệu lớn để hội tụ tốt do số lượng tham số khổng lồ. - Nhạy cảm với nhiễu nền nếu không có cơ chế định hướng sự chú ý tường minh.
Tree-based Decoding Methods	- Bảo toàn tốt cấu trúc tô-pô và ngữ nghĩa của biểu thức, tránh sinh ra chuỗi vô nghĩa. - Giảm thiểu việc sinh ra các chuỗi sai cú pháp LaTeX cơ bản. - Hiệu quả cao đối với các biểu thức có độ sâu cấu trúc lớn (nested structures) như phân số lồng nhau.	- Cấu trúc giải mã phức tạp, khó triển khai và huấn luyện hơn giải mã tuần tự. - Tốc độ suy diễn thường chậm hơn do quy trình duyệt cây phức tạp. - Phụ thuộc vào định nghĩa cây cú pháp chuẩn, có thể gặp khó khăn nếu cấu trúc nhập nhằng hoặc có nhiều cách biểu diễn.
Vision-Language Models (VLM)	- Tận dụng được tri thức từ các mô hình ngôn ngữ lớn đã pre-trained trên dữ liệu khổng lồ. - Khả năng tổng quát hóa mạnh mẽ (generalization) sang các miền dữ liệu mới. - Có khả năng suy luận đa bước (chain-of-thought).	- Yêu cầu tài nguyên tính toán và bộ nhớ rất lớn (VRAM) để triển khai. - Khó tinh chỉnh (fine-tune) để phù hợp với đặc thù cấu trúc 2D của HMER mà không làm mất tri thức gốc. - Tốc độ suy diễn chậm do kích thước mô hình lớn.

Bảng 2: Ưu và nhược điểm của các phương pháp

3 Cơ sở lý thuyết

3.1 Coverage Attention trong RNN

Cơ chế **Coverage Attention** đã được áp dụng rộng rãi trong các mô hình HMER dựa trên mạng RNN [7, 18, 26, 27, 30, 37, 38, 7]. **Coverage vector** cho mô hình biết thông tin về vùng ảnh đã được xử lý hay chưa. Giả sử encoder tạo ra các đặc trưng ảnh sau khi được trải phẳng $X_f \in \mathbb{R}^{L \times d_{model}}$ với độ dài chuỗi $L = h_0 \times w_0$. Tại từng thời điểm t , các **attention weights** a_k trước đó được "tích lũy" thành vector c_t , sau đó được biến đổi thành **coverage matrix** F_t :

$$c_t = \sum_{k=1}^{t-1} a_k \in \mathbb{R}^L \quad (1)$$

$$F_t = cov(c_t) \in \mathbb{R}^{L \times d_{attn}} \quad (2)$$

với $cov(\cdot)$ là kết hợp của một lớp tích chập 11×11 và một lớp tuyến tính.

Trong cơ chế **attention**, ta tính toán điểm tương đồng $e_{t,i}$ cho tất cả đặc trưng ảnh tại chỉ số $i \in [0, L)$. Bằng cách sử dụng các phép toán **broadcast**, ta có thể tính toán vector tương đồng e_t một cách song song bằng cách **broadcast** hidden state của RNN $h_t \in \mathbb{R}^{d_{model}}$ thành $H_t \in \mathbb{R}^{L \times d_{model}}$. Attention weight a_t của bước t được tính bởi công thức

$$e_t = \tanh(H_t W_h + X_f W_x + F_t) v_a \quad (3)$$

$$a_t = \text{softmax}(e_t) \in \mathbb{R}^L \quad (4)$$

$W_h \in \mathbb{R}^{d_{model} \times d_{attn}}$, $W_x \in \mathbb{R}^{d_{model} \times d_{attn}}$ là các ma trận tham số được huấn luyện và $v_a \in \mathbb{R}^{d_{attn}}$ là một vector tham số được huấn luyện

3.2 Multi-head Attention

Multi-head Attention được xem như là thành phần quan trọng nhất trong mô hình Transformer [28]. Với kích thước của mô hình d_{model} , độ dài chuỗi truy vấn (query) T và độ dài chuỗi khóa (key) L , phép tính Multi-head Attention cho $Head_i$ được chia thành bốn phần:

1. Chiếu các ma trận Q , K , V vào một không gian con khác.

2. Tính tích vô hướng có tỉ lệ $E_i \in \mathbb{T} \times \mathbb{L}$
3. Tính attention weights $A_i \in \mathbb{R}^{T \times L}$ sử dụng hàm softmax
4. $Head_i$ được tính bằng cách nhân trọng số A_i với V_i

$$Q_i = QW_i^Q, \quad K_i = KW_i^K, \quad V_i = VW_i^V \quad (5)$$

$$E_i = \frac{Q_i K_i^T}{\sqrt{d_k}} \in \mathbb{T} \times \mathbb{L} \quad (6)$$

$$A_i = \text{softmax}(E_i) \in \mathbb{R}^{T \times L} \quad (7)$$

$$Head_i = A_i V_i \in \mathbb{R}^{T \times d_v} \quad (8)$$

trong đó W_i^Q, W_i^K, W_i^V biểu thị các ma trận tham số cho phép chiếu. Cuối cùng, tất cả h -heads được nối lại và chiếu thông qua ma trận W^O để thu được kết quả

$$MultiHead(Q, K, V) = [Head_1; Head_2; \dots; Head_h]W^O \quad (9)$$

3.3 CNN Encoder

Với encoder, nhóm tác giả sử dụng DenseNet [11] để trích xuất các đặc trưng từ ảnh với lý do DenseNet giúp tăng thông tin giữa các lớp thông qua phép concatenate theo chiều của các đặc trưng (feature dimension). Với khối DenseNet thứ b , đặc trưng đầu ra của lớp thứ l được tính toán từ các đặc trưng đầu ra của các lớp đó $X_0, X_1, \dots, X_{l-1}$

$$X_l = H_l([X_0; x_1; \dots; X_{l-1}]) \in \mathbb{R}^{h_b \times w_b \times d_b} \quad (10)$$

trong đó $[X_0; x_1; \dots; X_{l-1}]$ là phép concatenate, d_b là feature dimension của block và hàm $H_l(\cdot)$ bao gồm một Batch Normalization layer [12], một ReLU Activation function [9] và một Convolution layer 3×3 . Cuối encoder, một Convolution layer 1×1 được sử dụng để điều chỉnh kết quả đầu ra của DenseNet phù hợp với kích thước của mô hình d_{model}

3.4 Positional Encoding

Khác với RNN có tính tuần tự, thông tin về vị trí là một thành phần bắt buộc trong Transformer do tính chất bất biến với hoán vị (permutation-invariant). Đối với **Word**

Positional Encoding, ta sử dụng cơ chế được trình bày trong Transformer gốc [28]. Với kích thước mã hóa d , vị trí p và chỉ số feature dimension i , Word Positional Encoding vector $p_{p,d}^W \in \mathbb{R}^d$ được biểu diễn ở dạng

$$\begin{aligned} p_{p,d}^W[2i] &= \sin(p/10000^{2i/d}) \\ p_{p,d}^W[2i+1] &= \cos(p/10000^{2i/d}) \end{aligned} \quad (11)$$

Đối với **Image Positional Encoding**, ta sử dụng **normalized positional encoding**. Vì vị trí tương đối giữa các ký tự với nhau quan trọng hơn vị trí tuyệt đối của chúng nên các tọa độ cần được chuẩn hóa từ trước. Với tọa độ (x, y) và kích thước mã hóa d , Image Positional Encoding vector $p_{x,y,d}^I \in \mathbb{R}^d$ được tính bằng cách concatenate hai 1D Positional Encoding theo phương trình (11)

$$\bar{x} = \frac{x}{h_0}, \quad \bar{y} = \frac{y}{w_0} \quad (12)$$

$$p_{x,y,d}^I = [p_{\bar{x},d/2}^W; p_{\bar{y},d/2}^W] \quad (13)$$

với h_0 và w_0 là số chiều của image feature đầu ra $X_0 \in \mathbb{R}^{h_0 \times w_0 \times d_{model}}$

4 Thí nghiệm ban đầu và phân tích thất bại

Trong quá trình phát triển hệ thống Nhận dạng biểu thức toán học viết tay (HMER), trước khi đi đến giải pháp đề xuất chính thức, đề án đã tiến hành một loạt các thí nghiệm dựa trên các mô hình ngôn ngữ lớn (LLM) và mô hình thị giác - ngôn ngữ (VLM). Chương này trình bày chi tiết quá trình thực nghiệm, các kết quả thu được, đồng thời phân tích các hạn chế kỹ thuật và nguyên nhân dẫn đến việc các hướng tiếp cận này không đạt hiệu quả mong đợi trên tập dữ liệu CROHME. Những phân tích này đóng vai trò nền tảng cho việc chuyển hướng sang phương pháp tập trung vào cấu trúc được đề xuất ở các chương sau.

4.1 Động cơ và giả thuyết ban đầu

Sự phát triển mạnh mẽ của các mô hình đa phương thức (Multi-modal Learning) như BLIP-2 [16] hay các kiến trúc VLM gần đây đã cho thấy khả năng vượt trội trong việc kết hợp thông tin thị giác và văn bản. Trong ngữ cảnh HMER, bài toán có thể được xem xét như một nhiệm vụ *Image Captioning* chuyên biệt, nơi đầu vào là ảnh công thức và đầu ra là chuỗi LaTeX.

Giả thuyết ban đầu của đề án dựa trên hai luận điểm chính:

- Khả năng ngôn ngữ của LLM:** Các LLM (như GPT-2, LLaMA) có khả năng sinh văn bản mạnh mẽ, hứa hẹn sẽ giải quyết tốt các vấn đề về cú pháp LaTeX phức tạp mà các decoder truyền thống (RNN/GRU) thường gặp khó khăn.
- Cơ chế cầu nối (Bridge Mechanism):** Việc sử dụng các module trung gian như Q-Former [16] có thể giúp trích xuất các đặc trưng ngữ nghĩa cao cấp từ ảnh viết tay để điều hướng LLM sinh chuỗi chính xác.

Các nghiên cứu gần đây như Uni-MuMER[17] cũng đã bắt đầu khai thác hướng đi này, tạo động lực cho việc thử nghiệm một kiến trúc lai giữa Vision Encoder và LLM Decoder cho bài toán HMER.

4.2 Thí nghiệm 1: Tiếp cận end-to-end HMER với VLM

Trong lần thử nghiệm đầu tiên, đề án xây dựng một kiến trúc VLM tiêu chuẩn được huấn luyện end-to-end trên tập dữ liệu CROHME.

4.2.1 Thiết lập thí nghiệm

Kiến trúc mô hình bao gồm ba thành phần chính:

- **Image Encoder:** Sử dụng ResNet-101 [10] để trích xuất đặc trưng từ ảnh đầu vào.
- **Bridge Module:** Sử dụng Q-Former (khởi tạo từ BLIP-2) với các learnable query tokens để nén thông tin thị giác và chuyển đổi sang không gian embedding của ngôn ngữ.
- **Decoder:** Sử dụng GPT-2 [24] (small version) làm decoder, tận dụng tokenizer có sẵn để sinh chuỗi LaTeX.

4.2.2 Kết quả và Quan sát

Mô hình được huấn luyện với hàm mục tiêu Cross-Entropy tiêu chuẩn. Kết quả thực nghiệm trên tập validation cho thấy sự chênh lệch lớn giữa hiệu suất huấn luyện và kiểm thử:

Metric	Training	Validation	Nhận xét
Loss	≈ 0.45	≈ 2.62	Chênh lệch loss lớn (High Variance)
ExpRate	-	$\approx 2.1\%$	Khả năng nhận dạng mức câu rất thấp
Token Acc	-	$\approx 35\%$	Dự đoán sai nhiều token cấu trúc

Bảng 3: Kết quả thực nghiệm ban đầu với kiến trúc VLM End-to-End

Phân tích hiện tượng: Mặc dù Training Loss giảm nhanh và hội tụ về mức thấp, Validation Loss không giảm tương ứng và có xu hướng dao động mạnh. Hiện tượng overfitting diễn ra nghiêm trọng ngay từ các epoch đầu tiên. Mô hình có xu hướng "ghi nhớ" các mẫu trong tập train nhưng thất bại hoàn toàn trong việc tổng quát hóa các quan hệ không gian 2D trên dữ liệu chưa nhìn thấy.

4.3 Thí nghiệm 2: Bổ sung giám sát cấu trúc và pipeline hai giai đoạn

Nhận thấy việc học end-to-end không hiệu quả do thiếu sự giám sát tường minh về cấu trúc toán học, thí nghiệm thứ hai được thiết kế nhằm bổ sung thông tin ngữ cảnh và cấu trúc cho LLM.

4.3.1 Cải tiến phương pháp

Đề án chuyển sang chiến lược huấn luyện hai giai đoạn (2-stage pipeline) và tích hợp thêm các module hỗ trợ:

- **Global Text Descriptor (GTD):** Bổ sung một nhánh phụ trợ để dự đoán thông tin văn bản toàn cục, lấy cảm hứng từ kiến trúc TAMER [44], nhằm cung cấp ngữ cảnh "gợi ý" cho Decoder.
- **TexFusion Module:** Tích hợp cơ chế trộn đặc trưng (feature fusion) giữa đặc trưng ảnh (visual features) và đặc trưng văn bản dự đoán (textual features) trước khi đưa vào LLM.

4.3.2 Kết quả thực nghiệm

Sau khi tinh chỉnh siêu tham số, hiệu năng mô hình có sự cải thiện nhưng vẫn chưa đạt ngưỡng chấp nhận được cho bài toán HMER:

- **ExpRate:** Tăng nhẹ lên mức $\approx 10\%$.
- **Token Accuracy:** Đạt khoảng 60%.
- **Vấn đề tồn đọng:** Mặc dù độ chính xác cấp độ token tăng, mô hình vẫn thường xuyên sai sót ở các cấu trúc lồng ghép phức tạp (như phân số lồng nhau, chỉ số trên/dưới). Q-Former vẫn đóng vai trò là "nút cổ chai" (bottleneck), làm mất mát thông tin vị trí quan trọng của các ký tự nhỏ.

4.4 Phân tích nguyên nhân và bài học rút ra

Dựa trên kết quả của hai thí nghiệm trên, đề án tiến hành phân tích các nguyên nhân cốt lõi dẫn đến sự kém hiệu quả của hướng tiếp cận dựa trên LLM/VLM đối với tập dữ liệu CROHME:

4.4.1 Hạn chế về quy mô dữ liệu

Các mô hình LLM và VLM yêu cầu lượng dữ liệu khổng lồ để hội tụ. Tập dữ liệu CROHME (với khoảng 8.000 - 10.000 mẫu huấn luyện) là quá nhỏ để *fine-tune* hiệu quả một mô hình có hàng triệu tham số như GPT-2 hay Q-Former. Việc áp dụng các mô hình này dẫn đến hiện tượng "học vẹt" thay vì học các đặc trưng bất biến của biểu thức toán học.

4.4.2 Sự lệch pha về không gian đặc trưng

- **Embedding Space:** Không gian embedding của GPT-2 được tối ưu cho ngôn ngữ tự nhiên (tiếng Anh), trong khi ngôn ngữ toán học (LaTeX) có cấu trúc cú pháp và phân bố token hoàn toàn khác biệt. Việc ép buộc tokenizer của GPT-2 học lại cú pháp toán học từ đầu trên dữ liệu nhỏ gây ra sự xung đột trong biểu diễn tri thức.
- **Q-Former Bottleneck:** Đối với HMER, thông tin không gian (vị trí tương đối giữa các nét bút) quan trọng hơn ngữ nghĩa hình ảnh tổng quát. Cơ chế của Q-Former có xu hướng nén thông tin thị giác thành các query tokens trừu tượng, vô tình loại bỏ các chi tiết vị trí tinh tế cần thiết để phân biệt các cấu trúc như 2^x (superscript) và $2x$ (inline).

4.5 Điều chỉnh và nỗ lực khắc phục

Đồ án đã thử nghiệm một số kỹ thuật nhằm giảm thiểu các vấn đề trên, bao gồm:

- **Feature Normalization:** Chuẩn hóa đặc trưng đầu ra của Encoder theo mean/std của không gian embedding LLM để hỗ trợ quá trình hội tụ.
- **Frozen LLM Backbone:** Đóng băng trọng số của LLM và chỉ huấn luyện Q-Former để tránh hiện tượng *catastrophic forgetting*.

Tuy nhiên, các điều chỉnh này chỉ mang lại cải thiện cục bộ về mặt chỉ số Loss mà không giải quyết triệt để vấn đề sai lệch cấu trúc (structural errors) trong kết quả dự đoán. ExpRate vẫn dậm chân tại chỗ ở mức thấp.

4.6 Tổng kết và định hướng giải pháp

Từ chuỗi thí nghiệm thăm dò và phân tích thất bại nêu trên, đồ án rút ra kết luận:

"Việc áp dụng trực tiếp các kiến trúc VLM/LLM hạng nặng (heavy-weight) cho bài toán HMER trên tập dữ liệu giới hạn như CROHME là không tối ưu. Bài toán HMER đòi hỏi một cơ chế chuyên biệt để xử lý mối quan hệ không gian 2D (Spatial Relations) hơn là khả năng sinh văn bản tự do của LLM."

Kết luận này là cơ sở quan trọng để đồ án chuyển hướng nghiên cứu sang:

1. Sử dụng kiến trúc **Encoder-Decoder với Transformer thuần túy** (nhẹ hơn, dễ huấn luyện hơn) làm nền tảng.

2. Tập trung vào việc mô hình hóa và bảo toàn **thông tin cấu trúc** thông qua các ràng buộc hình học (Geometric Constraints) thay vì phụ thuộc vào tri thức ngôn ngữ tiền huấn luyện.

4.7 Thí nghiệm 3: Encoder-Decoder với Transformer thuần và tác động của học đa nhiệm

Sau khi xác định được tính không khả thi của việc áp dụng trực tiếp các mô hình ngôn ngữ lớn (VLM/LLM) cho dữ liệu CROHME (như đã trình bày ở Mục 4), thí nghiệm thứ ba nhằm quay trở lại nền tảng cơ bản: mô hình Sequence-to-Sequence chuyên biệt. Mục tiêu của thí nghiệm này là kiểm chứng hiệu quả của kiến trúc Encoder-Decoder thuần túy và đánh giá tác động của học đa nhiệm (Multi-task Learning - MTL) đối với khả năng tổng quát hóa của mô hình.

4.7.1 Thiết lập mô hình

Khác với cách tiếp cận dựa trên tri thức tiền huấn luyện (Pre-trained Knowledge) ở các thí nghiệm trước, mô hình trong thí nghiệm này được xây dựng để học từ đầu (scratch) trên dữ liệu CROHME.

- **Encoder:** Sử dụng mạng DenseNet (Dense Convolutional Network) [11] để trích xuất đặc trưng ảnh. Đây là kiến trúc tiêu chuẩn trong cộng đồng HMER nhờ khả năng tái sử dụng đặc trưng và giảm thiểu tham số.
- **Decoder:** Sử dụng kiến trúc Transformer Decoder tiêu chuẩn với cơ chế Self-Attention và Cross-Attention. Tại giai đoạn này, chưa áp dụng cơ chế Coverage để quan sát hành vi gốc của Attention.
- **Đầu ra:** Chuỗi token LaTeX được sinh ra trực tiếp.

Để kiểm chứng giả thuyết về học đa nhiệm, đề án thiết kế mô hình với một nhánh chính (Main Task - nhận dạng chuỗi) và một nhánh phụ trợ (Auxiliary Tasks) được thiết kế y chang với nhánh chính, hoạt động song song tại đầu ra của Encoder, ba nhiệm vụ của nhánh phụ trợ là:

1. *Symbol Type Prediction:* Phân loại loại ký tự (số, chữ cái, toán tử).
2. *Structure Depth Prediction:* Dự đoán độ sâu của cấu trúc cây cú pháp.

3. *Relation Prediction*: Dự đoán mối quan hệ cơ bản giữa các ký tự liền kề.

4.7.2 Các biến thể thí nghiệm

Quá trình thực nghiệm được tiến hành trên bốn biến thể cấu hình để cô lập các yếu tố tác động:

1. **Baseline Transformer thuần (Vanilla)**: Chỉ huấn luyện với hàm mất mát Cross-Entropy trên chuỗi đích, không sử dụng nhiệm vụ phụ trợ.
2. **Transformer + Naive MTL**: Kích hoạt đồng thời cả 3 nhánh phụ trợ với trọng số loss ngang bằng nhau. Mục đích là quan sát sự tương tác gradient giữa các tác vụ.
3. **Transformer + Tuned MTL**: Điều chỉnh hệ số trọng số (λ) cho các nhiệm vụ phụ trợ thấp hơn nhiệm vụ chính nhằm đóng vai trò như một bộ điều chỉnh (regularizer), giảm thiểu hiện tượng overfitting.
4. **Grammar-constrained Decoding**: Áp dụng các luật cú pháp cứng (hard-coded grammar rules) tại giai đoạn suy luận (inference) để loại bỏ các chuỗi LaTeX không hợp lệ.

4.7.3 Kết quả định lượng

Kết quả thực nghiệm trên tập validation cho thấy sự khác biệt rõ rệt so với hướng tiếp cận VLM trước đó:

4.7.3.1 Hiệu năng cơ sở: Mô hình Transformer thuần đạt độ chính xác token (Token Accuracy) khoảng $\approx 83\%$ và tỷ lệ nhận dạng biểu thức chính xác (ExpRate) dao động trong khoảng $27\% - 30\%$. Mặc dù con số này chưa cao so với SOTA, nhưng nó vượt trội hoàn toàn so với mức 2% của VLM, chứng minh rằng kiến trúc chuyên biệt phù hợp hơn với quy mô dữ liệu hiện có.

4.7.3.2 Tác động của học đa nhiệm: Khi áp dụng MTL với trọng số được tinh chỉnh (Tuned MTL), hiệu năng có sự cải thiện đáng kể:

- **Token Accuracy**: Tăng lên mức $\approx 94\%$. Điều này cho thấy các nhiệm vụ phụ trợ giúp Encoder học được các biểu diễn đặc trưng phân biệt (discriminative features) tốt hơn.
- **ExpRate**: Tỷ lệ nhận dạng chính xác hoàn toàn vẫn còn khiêm tốn, nhưng tỷ lệ sai sót nhỏ ($\text{ExpRate} \leq 3$ lỗi) đạt khoảng $50\% - 63\%$.

4.7.3.3 Hạn chế của ràng buộc cú pháp: Biến thể *Grammar-constrained Decoding* không mang lại cải thiện về ExpRate, thậm chí làm giảm tốc độ suy luận. Nguyên nhân là do các luật cứng không bao quát được sự đa dạng của chữ viết tay và dễ dẫn đến lỗi dây chuyền (error propagation) khi một token bị nhận dạng sai.

4.7.4 Phân tích và thảo luận

Kết quả từ thí nghiệm này cung cấp những góc nhìn quan trọng về hành vi của mô hình:

1. Sự ưu việt của mô hình chuyên biệt: Transformer-based thuần túy cho thấy khả năng hội tụ ổn định hơn nhiều so với VLM. Việc loại bỏ sự phụ thuộc vào tokenizer ngôn ngữ tự nhiên (như GPT-2) giúp mô hình tập trung hoàn toàn vào cú pháp LaTeX đặc thù của toán học.

2. Học đa nhiệm là "con dao hai lưỡi": Mặc dù MTL giúp cải thiện độ chính xác ở cấp độ token, nhưng quan sát thấy hiện tượng mất ổn định trong quá trình giải mã chuỗi dài. Việc này cũng đã được chứng minh ở MMHMER [5]. Các nhiệm vụ phụ trợ hiện tại (phân loại type, depth) mang tính chất *rời rạc* (discrete) và *tĩnh* (static). Chúng giúp Encoder hiểu "đây là ký tự gì", nhưng không cung cấp đủ thông tin hướng dẫn cho Decoder biết "đang ở đâu" hoặc "cần nhìn vào đâu tiếp theo".

3. Vấn đề về kiểm soát Attention: Các lỗi phổ biến nhất là lặp lại ký tự hoặc bỏ sót các thành phần nhỏ (như dấu trừ, dấu chấm). Điều này chỉ ra rằng cơ chế Attention tiêu chuẩn thiếu một sự ràng buộc về "độ bao phủ" (coverage), dẫn đến việc chú ý dư thừa hoặc thiếu hụt vào các vùng ảnh.

4.7.5 Tổng kết và định hướng giải pháp

Từ chuỗi các thí nghiệm thăm dò (4.2 đến 4.7), đề án rút ra các kết luận then chốt định hình nên phương pháp đề xuất của đề án:

- 1. Nền tảng kiến trúc:** Transformer-based là lựa chọn tối ưu cho bài toán HMER với dữ liệu hạn chế. Tuy nhiên, cần một cơ chế Attention mạnh mẽ hơn cơ chế tiêu chuẩn.
- 2. Sự cần thiết của thông tin liên tục:** Các nhiệm vụ phụ trợ phân loại rời rạc là chưa đủ. Để giải quyết các lỗi cấu trúc (như sai vị trí tử số/mẫu số), mô hình cần học được các đặc trưng mang tính *không gian* (spatial) và *quan hệ* (relational) một cách liên tục.

3. **Cơ chế hướng dẫn trực tiếp:** Thay vì chỉ dùng loss phụ trợ để tinh chỉnh Encoder một cách thụ động, cần một cơ chế để cung cấp trực tiếp các thông tin cấu trúc và độ bao phủ vào quá trình giải mã của Decoder.

Những nhận định này dẫn dắt đề án đến việc đề xuất giải pháp của đề án: **Mô hình Transformer với các ràng buộc cấu trúc Không gian - Quan hệ (SRSC)**. Cụ thể, đề án sẽ thay thế các nhiệm vụ phụ trợ rời rạc bằng các bản đồ phân bố không gian (*Spatial Distribution Map*) và bản đồ quan hệ (*Structural Relation Map*), đồng thời tích hợp chúng vào cơ chế *Guided Coverage Attention* [41] để kiểm soát toàn diện quá trình sinh biểu thức. Chi tiết phương pháp sẽ được trình bày trong Chương 5.

5 Giải pháp đề xuất

5.1 Định nghĩa vấn đề

Trước khi đi vào chi tiết giải pháp đề xuất, phần này sẽ thiết lập cơ sở toán học cho bài toán Nhận dạng biểu thức toán học viết tay (HMER), phân tích cơ chế Coverage trong mô hình cơ sở CoMER[41], và định nghĩa bài toán tối ưu hóa đa nhiệm mà đề án hướng tới giải quyết.

5.1.1 Phát biểu bài toán HMER

Bài toán HMER có thể được mô hình hóa như một bài toán ánh xạ từ không gian hình ảnh sang chuỗi ký tự. Cho tập dữ liệu $\mathcal{D} = \{(\mathbf{I}_n, \mathbf{Y}_n)\}_{n=1}^N$, trong đó:

- $\mathbf{I} \in \mathbb{R}^{H \times W \times C}$ là hình ảnh đầu vào chứa biểu thức toán học viết tay (thường $C = 1$ đối với ảnh xám nhị phân).
- $\mathbf{Y} = \{y_1, y_2, \dots, y_L\}$ là chuỗi đích (target sequence) tương ứng gồm L token LaTeX, với $y_t \in \mathcal{V}$ (tập từ vựng).

Mục tiêu của bài toán là tìm kiếm một mô hình tham số hóa θ để tối đa hóa xác suất có điều kiện của chuỗi đích $\mathbf{Y}$ khi biết hình ảnh đầu vào $\mathbf{I}$:

$$\hat{\theta} = \arg \max_{\theta} \sum_{(\mathbf{I}, \mathbf{Y}) \in \mathcal{D}} \log P(\mathbf{Y} | \mathbf{I}; \theta) \quad (14)$$

Theo nguyên lý phân rã chuỗi (chain rule), xác suất này được tính bằng tích xác suất của từng token tại bước thời gian t , phụ thuộc vào các token trước đó $\mathbf{y}_{<t}$ và đặc trưng ảnh:

$$P(\mathbf{Y} | \mathbf{I}) = \prod_{t=1}^L P(y_t | \mathbf{y}_{<t}, \mathbf{I}) \quad (15)$$

5.1.2 Phân tích cơ chế Coverage trong CoMER và Hạn chế

Mô hình CoMER (Baseline) sử dụng kiến trúc Encoder-Decoder với cơ chế Attention. Tại mỗi bước giải mã t , mô hình tính toán trọng số chú ý (attention weight) $\alpha_{t,i}$ cho từng vị trí i trên bản đồ đặc trưng (feature map) của Encoder.

Để giải quyết vấn đề lặp lại hoặc thiếu sót nét (under/over-parsing), CoMER tích hợp cơ

chế **Coverage Attention**. Cơ chế này duy trì một vector bao phủ tích lũy $\mathbf{C}_t$, đại diện cho tổng lịch sử chú ý của mô hình tính đến bước trước đó ($t - 1$):

$$\mathbf{C}_t = \sum_{\tau=1}^{t-1} \alpha_{\tau} \quad (16)$$

Trong đó, α_{τ} là bản đồ phân bố chú ý tại bước τ . Trong quá trình tính toán điểm chú ý (attention score) cho bước t , CoMER sử dụng $\mathbf{C}_t$ như một thành phần phạt (penalty term) hoặc bộ lọc để điều chỉnh trọng số chú ý chưa chuẩn hóa (raw attention scores) $e_{t,i}$:

$$\hat{e}_{t,i} = e_{t,i} - \lambda \cdot \psi(\mathbf{C}_{t,i}) \quad (17)$$

Với $\psi(\cdot)$ là một hàm biến đổi (ví dụ: tích chập 1×1 hoặc hàm phi tuyến) và λ là hệ số điều chỉnh.

Hạn chế cốt lõi: Mặc dù vector $\mathbf{C}_t$ giúp mô hình "ghi nhớ" các vùng đã đi qua, nhưng nó được học một cách thụ động (implicit) hoàn toàn dựa trên hàm mất mát tái tạo chuỗi ký tự ($\mathcal{L}_{rec}$).

- Không có ràng buộc nào đảm bảo rằng α_t thực sự tập trung vào vùng chứa nét viết (stroke regions).
- Mô hình không phân biệt được giữa vùng nền nhiễu (background noise) và vùng ký tự thực sự nếu không có tín hiệu giám sát không gian tường minh.
- Công thức tính $\mathbf{C}_t$ coi trọng số chú ý ở mọi vị trí là như nhau, không trọng số hóa dựa trên mật độ thông tin (stroke density) của vùng ảnh.


5.2 Tổng quan giải pháp đề xuất

Để giải quyết các hạn chế căn bản của mô hình cơ sở CoMER trong việc mô hình hóa sự phụ thuộc không gian và cấu trúc (như đã phân tích tại Phần 5.1.2), đề án đề xuất một kiến trúc mạng nơ-ron học đa nhiệm mới với tên gọi **SRSC: Spatial and Relational Structural Constraints for Transformer-based Handwritten Mathematical Expression Recognition**, tích hợp tri thức hình học tường minh vào quá trình nhận dạng.

Cách tiếp cận của đề án không chỉ dừng lại ở việc bổ sung các nhánh phụ trợ để hỗ trợ

huấn luyện, mà còn can thiệp trực tiếp vào quá trình suy diễn (inference) thông qua cơ chế hướng dẫn sự chú ý. Mục tiêu cốt lõi của giải pháp là chuyển đổi cơ chế bao phủ (coverage mechanism) từ trạng thái *thụ động*—hoàn toàn dựa vào lịch sử chú ý trong quá khứ—sang trạng thái *chủ động*, được điều hướng bởi các bản đồ đặc trưng không gian và quan hệ hình học.

Kiến trúc tổng thể được xây dựng dựa trên sự phối hợp chặt chẽ của ba thành phần chính: (1) Khung học tập đa nhiệm (Multi-task Learning Framework), (2) Cơ chế giải mã có hướng dẫn (Guided Decoding), và (3) Hàm mục tiêu tổng hợp. Sơ đồ tổng quát của phương pháp được minh họa trong Hình 1.



Hình 1: Tổng quan kiến trúc SRSC

5.2.1 Khung học tập đa nhiệm (Multi-task Learning Framework)

Hệ thống được thiết kế để tối ưu hóa đồng thời ba mục tiêu học tập. Bên cạnh nhiệm vụ chính là nhận dạng chuỗi, hai nhiệm vụ phụ trợ được thiết kế nhằm cung cấp tín hiệu giám sát giàu thông tin hình học cho bộ mã hóa (Encoder).

1. **Nhiệm vụ chính: Nhận dạng biểu thức toán học (HMER).** Đây là luồng xử lý cốt

lỗi, đóng vai trò ánh xạ hình ảnh đầu vào $\mathbf{I}$ sang chuỗi mã LaTeX đích $\mathbf{Y} = \{y_1, y_2, \dots, y_L\}$. Mô hình được huấn luyện để tối đa hóa xác suất có điều kiện $P(\mathbf{Y}|\mathbf{I})$ theo cơ chế Sequence-to-Sequence tiêu chuẩn.

2. **Nhiệm vụ phụ trợ 1: Khôi phục phân bố không gian (Spatial Distribution Recovery).** Mô hình học cách dự đoán bản đồ mật độ nét viết (stroke density map) $\hat{\mathbf{S}} \in [0, 1]^{H' \times W'}$, nhằm xấp xỉ bản đồ nhãn $\mathbf{S}_{gt}$.

- *Động lực thiết kế:* Trong ảnh biểu thức toán học, phần lớn diện tích là nền trắng (background). Nhiệm vụ này đặt ra ràng buộc Encoder phải phân tách triệt để giữa vùng chứa thông tin hữu ích (foreground strokes) và vùng nhiễu, từ đó tạo ra các bản đồ đặc trưng tập trung (localized feature maps).

3. **Nhiệm vụ phụ trợ 2: Dự đoán quan hệ cấu trúc (Structural Relation Prediction).** Mô hình dự đoán tensor quan hệ $\hat{\mathbf{R}} \in [0, 1]^{C \times H' \times W'}$, trong đó C là số lượng lớp quan hệ hình học (ví dụ: Above, Below, Superscript, Subscript).

- *Động lực thiết kế:* Các ký tự trong biểu thức toán học thường có hình dạng giống nhau nhưng mang ý nghĩa khác nhau tùy thuộc vào vị trí (ví dụ: x^2 và x_2). Nhiệm vụ này cung cấp tri thức ngữ nghĩa cấp cao, giúp mô hình phân biệt các trường hợp nhập nhằng dựa trên vị trí tương đối thay vì chỉ dựa vào ngữ cảnh chuỗi ký tự.

5.2.2 Cơ chế Giải mã có hướng dẫn (Guided Decoding Mechanism)

Điểm đổi mới quan trọng trong giải pháp đề xuất là việc tái sử dụng đầu ra của các nhánh phụ trợ để tinh chỉnh quá trình giải mã. Thay vì để mô-đun Tinh chỉnh Chú ý (Attention Refinement Module - ARM) của CoMER hoạt động độc lập, đề án đề xuất cơ chế **Guided Coverage**.

Cụ thể, vector bao phủ (coverage vector) đại diện cho lịch sử chú ý của mô hình sẽ được trọng số hóa lại dựa trên thông tin từ bản đồ không gian $\hat{\mathbf{S}}$ và bản đồ quan hệ $\hat{\mathbf{R}}$. Công thức tính toán hình phạt (penalty) cho cơ chế chú ý được đề xuất như sau:

$$\text{penalty}_{guided}^{(t,i)} = \text{penalty}_{base}^{(t,i)} \times \left(1 + \alpha_s \cdot \hat{\mathbf{S}}^{(i)} + \alpha_r \cdot \max_k \hat{\mathbf{R}}^{(k,i)} \right) \quad (18)$$

Trong đó:

- $\text{penalty}_{base}^{(t,i)}$ là giá trị phạt gốc tích lũy từ các bước thời gian trước.
- $\hat{\mathbf{S}}^{(i)}$ và $\hat{\mathbf{R}}^{(k,i)}$ là giá trị dự đoán tại vị trí i trên bản đồ đặc trưng.
- α_s, α_r là các siêu tham số kiểm soát cường độ hướng dẫn.

Cơ chế này đảm bảo nguyên tắc: "Nếu một vùng chứa nét viết quan trọng hoặc mang cấu trúc phức tạp đã được chú ý, hình phạt áp dụng lên nó sẽ mạnh hơn để ngăn chặn việc lặp lại, trong khi các vùng nền sẽ chịu hình phạt thấp hơn."

5.2.3 Hàm mục tiêu tổng quát

Bài toán được mô hình hóa thành việc tìm kiếm bộ tham số tối ưu θ^* cho toàn bộ mạng nơ-ron nhằm cực tiểu hóa hàm mất mát tổng hợp $\mathcal{L}_{total}$, bao gồm sự đóng góp của cả ba nhiệm vụ:

$$\mathcal{L}_{total} = \mathcal{L}_{rec}(\mathbf{Y}, \hat{\mathbf{Y}}) + \lambda_s \cdot \mathcal{L}_{spatial}(\mathbf{S}_{gt}, \hat{\mathbf{S}}) + \lambda_r \cdot \mathcal{L}_{relation}(\mathbf{R}_{gt}, \hat{\mathbf{R}}) \quad (19)$$

Các thành phần của hàm mất mát được thiết kế chuyên biệt cho từng tác vụ:

- $\mathcal{L}_{rec}$: Sử dụng Cross-Entropy Loss để đảm bảo độ chính xác của chuỗi ký tự đầu ra.
- $\mathcal{L}_{spatial}$: Sử dụng Smooth L1 Loss để hồi quy mật độ điểm ảnh của nét viết, giúp mô hình định vị chính xác vị trí ký tự.
- $\mathcal{L}_{relation}$: Sử dụng Binary Cross-Entropy Loss cho bài toán phân loại đa nhãn tại từng điểm ảnh (pixel-wise multi-label classification), đóng vai trò như một bộ điều tiết cấu trúc (structural regularizer).
- λ_s, λ_r : Các trọng số cân bằng sự đóng góp của các luồng thông tin, được xác định thông qua thực nghiệm.

5.2.4 Vai trò kép của Kiến trúc Đề xuất

Thông qua thiết kế này, các thông tin không gian và cấu trúc đóng vai trò kép trong việc nâng cao hiệu suất nhận dạng:

1. **Tại Encoder (Feature Regularization):** Cơ chế học đa nhiệm hoạt động như một bộ điều tiết (regularizer), buộc Encoder phải trích xuất các đặc trưng thị giác giàu ngữ

nghĩa hơn. Các đặc trưng này không chỉ chứa thông tin hình dạng (texture) mà còn bao hàm thông tin định vị (localization) chính xác.

2. **Tại Decoder (Explicit Attention Guidance):** Cung cấp cơ chế hướng dẫn tường minh cho quá trình giải mã. Bằng cách tích hợp thông tin không gian vào hàm phạt coverage, mô hình giảm thiểu đáng kể lỗi trượt sự chú ý (attention drift), đặc biệt hiệu quả đối với các ký hiệu đa nét (như π , $\int$, $\sqrt{\dots}$) và các cấu trúc lồng ghép phức tạp.

Chi tiết kỹ thuật về cách xây dựng nhãn, kiến trúc mạng và quy trình lan truyền xuôi (forward pass) của từng thành phần sẽ được trình bày lần lượt trong các phần tiếp theo.

5.3 Chi tiết giải pháp

5.3.1 Cách tạo ra ground truth cho hai nhiệm vụ phụ

Để nâng cao khả năng nhận dạng của mô hình Encoder-Decoder cơ sở (CoMER) thông qua cơ chế học đa nhiệm (Multi-Task Learning), đề án đã thiết kế và tạo ra hai loại dữ liệu nhãn (ground truth) hỗ trợ: *Bản đồ phân bố không gian* (Spatial Distribution Map) và *Bản đồ quan hệ cấu trúc* (Structural Relation Map). Việc xây dựng các bản đồ này không chỉ cung cấp tín hiệu giám sát mạnh mẽ cho quá trình huấn luyện mà còn giúp bộ mã hóa (Encoder) học được các đặc trưng biểu diễn tốt hơn, bao gồm cả vị trí nét viết cục bộ và cấu trúc phân cấp toàn cục.

Quy trình tạo ground truth được thực hiện tự động dựa trên cặp dữ liệu ảnh đầu vào và chuỗi nhãn LaTeX tương ứng, đảm bảo tính chính xác về mặt điểm ảnh và sự nhất quán về mặt ngữ nghĩa toán học.

5.3.1.1 Tổng quan về biểu diễn Ground Truth Mục tiêu của đề án là ánh xạ thông tin từ không gian ảnh gốc kích thước $H \times W$ sang không gian đặc trưng của Encoder có kích thước $H' \times W'$. Dựa trên kiến trúc DenseNet được sử dụng làm xương sống (backbone), hệ số giảm kích thước (downsampling factor) là 16. Do đó, kích thước của các bản đồ ground truth được xác định là:

$$H' = \lceil H/16 \rceil, \quad W' = \lceil W/16 \rceil \quad (20)$$

Việc sử dụng hàm trần (ceil) đảm bảo kích thước của bản đồ ground truth luôn đồng bộ khớp nối với kích thước của feature map đầu ra từ Encoder, cho phép tính toán hàm lỗi (loss) trực


tiếp tại từng vị trí không gian.

5.3.1.2 Bản đồ phân bố không gian (Spatial Distribution Map) Bản đồ phân bố không gian, ký hiệu $S \in \mathbb{R}^{1 \times H' \times W'}$, đóng vai trò hướng dẫn Encoder tập trung vào các vùng chứa thông tin hữu ích (nét viết) và bỏ qua nền nhiễu.

Quy trình tạo:

- Nhị phân hóa ảnh:** Ảnh gốc thang độ xám được chuyển đổi sang ảnh nhị phân (binary) thông qua kỹ thuật phân ngưỡng thích nghi (adaptive thresholding). Bước này nhằm tách biệt hoàn toàn nét mực (foreground) và nền giấy (background).
- Tính toán mật độ cục bộ:** Ảnh nhị phân được chia thành lưới các ô (grid cells) với kích thước tương ứng với tỷ lệ giảm mẫu của Encoder. Tại mỗi ô (i, j) của lưới $H' \times W'$, giá trị của bản đồ $S_{i,j}$ được tính bằng mật độ điểm ảnh của nét viết trong vùng tương ứng trên ảnh gốc.
- Làm trơn:** Để giảm thiểu tác động của nhiễu và tạo ra một bề mặt gradient mượt mà hơn cho quá trình tối ưu hóa, bản đồ mật độ được làm trơn nhẹ bằng bộ lọc Gaussian và chuẩn hóa về miền giá trị $[0, 1]$.

Kết quả là một bản đồ nhiệt (heatmap) thể hiện xác suất tồn tại của nét viết tại mỗi vị trí đặc trưng, giúp mô hình định vị chính xác các vùng quan tâm (ROI).



Hình 2: Kết quả spatial ground truth tạo được

5.3.1.3 Bản đồ quan hệ cấu trúc (Structural Relation Map) Khác với bản đồ không gian chỉ mang thông tin thị giác cấp thấp, bản đồ quan hệ cấu trúc, ký hiệu $R \in \mathbb{R}^{7 \times H' \times W'}$, mã hóa các mối quan hệ hình học và ngữ nghĩa giữa các ký hiệu. Đây là thành phần quan trọng để giải quyết sự mơ hồ trong các cấu trúc lồng nhau phức tạp.

Định nghĩa tập quan hệ: đồ án định nghĩa 7 kênh quan hệ cơ bản để mô tả đầy đủ cấu trúc của biểu thức toán học:

- **Background (0):** Vùng nền không chứa ký hiệu.
- **Horizontal (1):** Ký hiệu nằm trên dòng cơ sở (baseline).
- **Above (2) / Below (3):** Ký hiệu thuộc tử số hoặc mẫu số trong phân số.
- **Superscript (4) / Subscript (5):** Ký hiệu nằm ở vị trí chỉ số trên hoặc chỉ số dưới.
- **Inside (6):** Ký hiệu nằm bên trong cấu trúc bao đóng (ví dụ: trong căn thức $\sqrt{\dots}$).

Tính chất đa nhãn (Multi-label Nature): Một điểm đột phá trong thiết kế ground truth này là tính chất đa nhãn tại mỗi vị trí không gian. Một ký hiệu trong biểu thức toán học phức tạp thường chịu sự chi phối của nhiều quan hệ cấu trúc đồng thời.

Ví dụ: Trong biểu thức $\sqrt{\frac{a}{b}}$:

- Ký hiệu a nằm trong căn thức (*Inside*) và nằm ở tử số (*Above*). Do đó, tại vị trí của a , các kênh tương ứng với *Inside* và *Above* đều được kích hoạt.
- Ký hiệu b nằm trong căn thức (*Inside*) và nằm ở mẫu số (*Below*).

Cách biểu diễn này cho phép mô hình học được cấu trúc phân cấp (hierarchical structure) thay vì chỉ học các quan hệ phẳng.

5.3.1.4 Quy trình ánh xạ ngữ nghĩa sang không gian ảnh Để tạo ra bản đồ quan hệ cấu trúc chính xác tới từng điểm ảnh (pixel-level accuracy), đồ án đề xuất quy trình gồm hai giai đoạn chính: Phân tích cú pháp và Render định danh màu.

1. Phân tích cú pháp ngữ cảnh (Context-aware Parsing): Chuỗi LaTeX đầu vào được phân tích bởi một parser chuyên dụng để xác định tập hợp các quan hệ cấu trúc cho từng ký hiệu. Parser này duy trì một ngăn xếp ngữ cảnh (context stack) để theo dõi độ sâu của cấu trúc lồng nhau.


- Khi gặp token bắt đầu cấu trúc (ví dụ: $\frac{}{}{\sqrt{}}{\blacksquare}$, $_$), parser đẩy quan hệ tương ứng vào ngăn xếp.
- Khi gặp token kết thúc, quan hệ tương ứng được loại bỏ khỏi ngăn xếp.

- Mỗi ký hiệu (token lá) sẽ thừa kế toàn bộ các quan hệ đang tồn tại trong ngăn xếp tại thời điểm đó.

2. Render mã hóa màu (Color-coded Rendering): Thách thức lớn nhất là xác định vị trí chính xác của từng ký hiệu trong ảnh để gán nhãn quan hệ. đề án giải quyết vấn đề này bằng kỹ thuật render với mã màu định danh:

1. Mỗi ký hiệu trong chuỗi LaTeX sau khi phân tích được gán một mã màu RGB duy nhất, khác biệt hoàn toàn với nhau và khác màu nền.
2. Sử dụng engine render (như XeLaTeX) để tạo ra ảnh biểu thức toán học từ chuỗi LaTeX đã được tô màu này.
3. Dựa vào mã màu, hệ thống quét toàn bộ ảnh render để xác định mặt nạ nhị phân (binary mask) vị trí của từng ký hiệu.
4. Các mặt nạ này sau đó được ánh xạ ngược lại với tập quan hệ đã phân tích ở bước 1 để điền vào các kênh tương ứng trong bản đồ quan hệ R .

Cuối cùng, bản đồ quan hệ R cũng được giảm kích thước (downsampling) tương tự như bản đồ phân bố không gian để đồng bộ với đầu ra của Encoder. Phương pháp này đảm bảo ground truth được tạo ra hoàn toàn tự động, có độ chính xác cao và phản ánh đúng bản chất cấu trúc phức tạp của biểu thức toán học viết tay.



Hình 3: Kết quả relation ground truth tạo được

5.3.2 Khôi phục Bản đồ Phân bố Không gian (Spatial Distribution Recovery)

Trong kiến trúc đề xuất, bên cạnh nhiệm vụ chính là giải mã chuỗi ký tự, đồ án giới thiệu nhiệm vụ phụ trợ (auxiliary task) đầu tiên: *Khôi phục Bản đồ Phân bố Không gian* (Spatial Distribution Recovery). Mục này trình bày cơ sở lý luận, định nghĩa toán học và vai trò của thành phần này trong việc định hình không gian đặc trưng của Bộ mã hóa (Encoder).

5.3.2.1 Động cơ thiết kế Trong các mô hình HMER dựa trên cơ chế Attention truyền thống (như CoMER), Bộ mã hóa chịu trách nhiệm trích xuất các đặc trưng thị giác từ ảnh đầu vào. Tuy nhiên, việc tối ưu hóa Encoder chỉ dựa trên tín hiệu từ hàm mất mát của chuỗi đích (Cross-Entropy Loss) bộc lộ những hạn chế đáng kể đối với đặc thù dữ liệu biểu thức toán học:

- **Sự thiếu hụt giám sát không gian tường minh (Lack of Explicit Spatial Supervision):** Cơ chế Attention học cách tập trung vào các vùng ảnh một cách ngầm định

(implicit). Không có ràng buộc trực tiếp nào đảm bảo rằng các trọng số chú ý (attention weights) thực sự phân bố trên các nét viết. Thực nghiệm cho thấy, mô hình thường xuyên gặp hiện tượng “trượt” sự chú ý (attention drift) sang các vùng nhiễu hoặc khoảng trắng vô nghĩa, dẫn đến lỗi lặp lại hoặc bỏ sót ký tự.

- **Mất cân bằng Tiền cảnh - Hậu cảnh (Foreground-Background Imbalance):**

Khác với ảnh phong cảnh tự nhiên, ảnh biểu thức toán học có mật độ thông tin rất thưa (sparse), với phần lớn diện tích là nền trắng (background). Nếu không có cơ chế định hướng, Encoder có xu hướng tạo ra các bản đồ đặc trưng với phản hồi yếu tại các chi tiết nhỏ (như dấu chấm, dấu phẩy, chỉ số) nhưng lại bị nhiễu nền chi phối.

Xuất phát từ thực tế đó, việc bổ sung một nhiệm vụ yêu cầu Encoder phải chủ động phân tách giữa “vùng chứa nét viết” (foreground strokes) và “vùng nền” (background) là điều kiện tiên quyết để nâng cao độ chính xác của quá trình trích xuất đặc trưng.

5.3.2.2 Định nghĩa Bản đồ Phân bố Không gian Bản đồ Phân bố Không gian, ký hiệu là $\mathbf{S}$, được định nghĩa là một ma trận xác suất thể hiện mật độ xuất hiện của các nét viết tại từng vị trí trên không gian đặc trưng.

Giả sử đầu ra của Encoder là tensor đặc trưng $\mathbf{F} \in \mathbb{R}^{H' \times W' \times D}$, trong đó H', W' là kích thước không gian đã được thu giảm (down-sampled) so với ảnh gốc, và D là số chiều đặc trưng. Bản đồ phân bố $\mathbf{S}$ được định nghĩa trong không gian $\mathbb{R}^{H' \times W'}$ với các tính chất sau:

- **Miền giá trị:** Mỗi phần tử $\mathbf{S}(i, j) \in [0, 1]$.
- **Ý nghĩa vật lý:** Giá trị $\mathbf{S}(i, j)$ đại diện cho xác suất (hoặc mức độ tin cậy) rằng tại vùng thụ cảm (receptive field) tương ứng với vị trí (i, j) có chứa thông tin nét viết.
 - $\mathbf{S}(i, j) \approx 1$: Vùng chứa nét viết đậm đặc (foreground).
 - $\mathbf{S}(i, j) \approx 0$: Vùng nền trắng hoàn toàn (background).
 - $0 < \mathbf{S}(i, j) < 1$: Các vùng biên nét viết hoặc các nét mảnh.

Như vậy, $\mathbf{S}$ đóng vai trò là một *bản đồ nhiệt* (heatmap), cung cấp tín hiệu giám sát mềm (soft spatial supervision) để định hướng sự tập trung của Encoder.

5.3.2.3 Vai trò trong Học đa nhiệm và Biểu diễn đặc trưng Nhiệm vụ Spatial Distribution Recovery được huấn luyện song song với nhiệm vụ chính HMER thông qua một

hàm mất mát hồi quy (regression loss) thích hợp. Sự tích hợp này mang lại hai tác động tích cực đối với Encoder:

- **Tăng cường khả năng định vị (Localization Enhancement):** Bằng cách buộc phải tái tạo lại bản đồ S_{gt} , Encoder bắt buộc phải mã hóa thông tin vị trí không gian vào trong tensor đặc trưng F . Các vector đặc trưng tại vị trí có nét viết sẽ mang ngữ nghĩa mạnh (high activation), trong khi các vector tại vùng nền bị triệt tiêu về giá trị gần 0.
- **Điều tiết cấu trúc (Structural Regularization):** Nhiệm vụ phụ trợ này đóng vai trò như một bộ điều tiết, ngăn chặn Encoder học các mối tương quan giả (spurious correlations) từ nền ảnh. Điều này giúp mô hình tổng quát hóa tốt hơn trên các dữ liệu có nhiều nền hoặc phong cách viết đa dạng.

Mặc dù Bản đồ Phân bố Không gian S không trực tiếp tham gia vào việc quyết định thứ tự sinh chuỗi ký tự, nhưng nó cung cấp nền tảng đặc trưng "sạch" và "giàu thông tin vị trí". Đây là tiền đề quan trọng để cơ chế Coverage Attention ở các tầng giải mã sau đó hoạt động chính xác và có định hướng hơn, thay vì phải tự dò tìm vùng quan trọng một cách mò mẫm.

5.3.3 Dự đoán Quan hệ Cấu trúc (Structural Relation Prediction)

Trong khi nhiệm vụ *Khôi phục Bản đồ Phân bố Không gian* (Phần 5.3.2) cung cấp sự giám sát ở cấp độ thị giác cơ bản (low-level visual supervision) để định vị nét viết, bài toán HMER còn đòi hỏi sự hiểu biết sâu sắc về các mối quan hệ hình học phức tạp. Mục này trình bày nhiệm vụ phụ trợ thứ hai: *Dự đoán Quan hệ Cấu trúc* (Structural Relation Prediction), đóng vai trò như một cơ chế giám sát ngữ nghĩa cấp cao (high-level semantic supervision).

5.3.3.1 Động cơ thiết kế Một thách thức cố hữu trong nhận dạng biểu thức toán học là sự “nhập nhằng về cấu trúc” (structural ambiguity). Trong không gian 2D, các ký tự có thể nằm rất gần nhau về khoảng cách Euclidean nhưng lại mang ý nghĩa cấu trúc hoàn toàn khác biệt tùy thuộc vào vị trí tương đối của chúng.

- **Ví dụ điển hình:** Xét hai trường hợp x^2 (lũy thừa) và x_2 (chỉ số dưới). Về mặt thị giác, sự khác biệt chỉ nằm ở sự dịch chuyển nhỏ theo trục dọc của số '2' so với 'x'. Nếu chỉ dựa vào cơ chế Attention theo chuỗi như CoMER, mô hình phải tự suy luận ngầm các quan hệ này thông qua thứ tự xuất hiện của token, điều này rất dễ gây lỗi khi gặp các cấu trúc lồng ghép nhiều tầng (như phân số lồng trong căn thức).

- **Hạn chế của giám sát chuỗi:** Việc chỉ huấn luyện Encoder-Decoder với nhãn chuỗi LaTeX tuyến tính khiến mô hình thiếu đi tri thức tiên nghiệm về không gian 2D. Encoder có thể trích xuất tốt hình dạng ký tự 'x' và '2', nhưng lại không mã hóa đủ thông tin để Decoder quyết định dứt khoát mối quan hệ giữa chúng là *Superscript*, *Subscript* hay *Horizontal* (nằm ngang hàng).

Do đó, việc bổ sung một nhiệm vụ yêu cầu Encoder phải nhận thức trực tiếp các mối quan hệ hình học là cần thiết để giải quyết triệt để các trường hợp nhập nhằng này ngay từ khâu trích xuất đặc trưng.

5.3.3.2 Định nghĩa Bản đồ Quan hệ Cấu trúc đề án mô hình hóa việc hiểu cấu trúc dưới dạng một bài toán *phân loại đa nhãn tại từng điểm ảnh* (pixel-wise multi-label classification). Đầu ra của nhiệm vụ này là tensor *Bản đồ Quan hệ Cấu trúc*, ký hiệu là $\mathbf{R}$.

Giả sử tensor đặc trưng đầu ra của Encoder là $\mathbf{F} \in \mathbb{R}^{H' \times W' \times D}$. Bản đồ quan hệ dự đoán $\mathbf{R}$ được định nghĩa trong không gian $\mathbb{R}^{C \times H' \times W'}$:

$$\mathbf{R} = \{\mathbf{R}_k\}_{k=1}^C, \quad \text{với } \mathbf{R}_k \in [0, 1]^{H' \times W'} \quad (21)$$

Trong đó:

- C là số lượng các lớp quan hệ hình học quan trọng được định nghĩa trước (ví dụ: *Superscript*, *Subscript*, *Above*, *Below*, *Inside*, *Horizontal*).
- Mỗi kênh $\mathbf{R}_k(i, j)$ biểu diễn xác suất để vùng đặc trưng tại vị trí (i, j) tham gia vào mối quan hệ loại k .
- **Tính chất đa nhãn:** Một vùng ảnh có thể đồng thời tham gia vào nhiều mối quan hệ (ví dụ: một ký tự có thể vừa là mẫu số của phân số này, vừa nằm trong căn thức khác). Do đó, hàm kích hoạt Sigmoid được sử dụng độc lập cho từng kênh thay vì Softmax.

Khác với Bản đồ phân bố $\mathbf{S}$ chỉ cho biết “có nét viết hay không”, Bản đồ quan hệ $\mathbf{R}$ trả lời câu hỏi “nét viết này đóng vai trò gì trong cấu trúc không gian”.

5.3.3.3 Vai trò: Bộ điều tiết Cấu trúc (Structural Regularizer) Nhiệm vụ Structural Relation Prediction được tích hợp vào mạng dưới dạng một nhánh phụ song song, huấn

luyện đồng thời với nhiệm vụ HMER chính. Vai trò của nó đối với quá trình học biểu diễn (Representation Learning) của Encoder được thể hiện qua hai khía cạnh:

1. **Mã hóa ngữ nghĩa hình học:** Thông qua quá trình lan truyền ngược (backpropagation) từ hàm mất mát phân loại quan hệ, Encoder buộc phải học cách nhúng (embed) thông tin về vị trí tương đối vào trong tensor đặc trưng $\mathbf{F}$. Các vector đặc trưng lúc này không chỉ mang thông tin về hình dạng ký tự mà còn chứa đựng cả ngữ nghĩa về vai trò cấu trúc của nó.
2. **Giảm thiểu gánh nặng suy diễn cho Decoder:** Thay vì để Decoder phải tự mày mò học lại các quy tắc không gian từ con số 0, Encoder (nhờ nhiệm vụ phụ trợ này) đã cung cấp sẵn một biểu diễn giàu tính cấu trúc. Điều này giúp Decoder ổn định hơn khi sinh các token định dạng cấu trúc (như '^', '_', '\frac'), giảm thiểu các lỗi cú pháp LaTeX.

5.3.3.4 Tác động đến khả năng hiểu biểu thức Việc tích hợp giám sát cấu trúc giúp mô hình cải thiện đáng kể khả năng xử lý các thành phần tinh tế của biểu thức toán học:

- **Phân biệt Superscript/Subscript:** Các quan hệ chỉ số trên/dưới được nhận diện rõ ràng nhờ vào các kênh quan hệ tương ứng trên bản đồ $\mathbf{R}$, thay vì chỉ dựa vào kích thước nhỏ hay vị trí lệch nhẹ của ký tự.
- **Xử lý cấu trúc lồng ghép (Nested Structures):** Đối với các biểu thức phức tạp như phân số liên tục hay căn thức lồng nhau, bản đồ quan hệ cung cấp các tín hiệu không gian tường minh (ví dụ: quan hệ *Inside*), giúp mô hình duy trì ngữ cảnh chính xác qua các bước giải mã dài.

Tóm lại, Structural Relation Prediction đóng vai trò là cầu nối ngữ nghĩa, chuyển hóa các thông tin hình ảnh thô thành các tri thức cấu trúc có ý nghĩa, tạo tiền đề vững chắc cho cơ chế giải mã có hướng dẫn (Guided Decoding) được trình bày trong phần tiếp theo.

5.3.4 Cơ chế Chú ý Bao phủ có Hướng dẫn (Guided Coverage Attention)

Trong khi các mục 5.3.2 và 5.3.3 tập trung vào việc nâng cao chất lượng biểu diễn đặc trưng tại Encoder, mục này sẽ trình bày cách thức các tri thức không gian và cấu trúc đó được tích hợp trực tiếp vào quá trình giải mã tại Decoder. đề án đề xuất cơ chế *Chú ý Bao phủ có Hướng dẫn* (Guided Coverage Attention), đóng vai trò là cầu nối trung tâm chuyển hóa các tín hiệu giám sát phụ trợ thành các quyết định điều hướng sự chú ý cụ thể.

5.3.4.1 Hạn chế của Cơ chế Coverage thụ động trong CoMER Mô hình cơ sở CoMER giải quyết vấn đề “trôi sự chú ý” (attention drift) thông qua một vector bao phủ (coverage vector) $\mathbf{C}_t$, được tích lũy từ tổng các trọng số chú ý trong quá khứ: $\mathbf{C}_t = \sum_{\tau=1}^{t-1} \mathbf{A}_\tau$. Trong Mô-đun Tinh chỉnh Chú ý (Attention Refinement Module - ARM), vector $\mathbf{C}_t$ được sử dụng để tạo ra một hình phạt (penalty) trừ vào điểm chú ý tại bước hiện tại, nhằm ngăn cản mô hình tập trung lại vào các vùng đã đi qua.

Tuy nhiên, cơ chế này mang tính chất "thụ động" và "mù nội dung" (content-agnostic):

- **Xử lý đồng nhất:** Cơ chế phạt áp dụng như nhau cho mọi vị trí trên bản đồ đặc trưng, bất kể đó là vùng chứa nét viết quan trọng hay vùng nền trắng vô nghĩa.
- **Thiếu tri thức hình học:** Vector bao phủ chỉ đơn thuần ghi nhớ “đã nhìn vào đâu” mà không biết “đã nhìn thấy gì”. Do đó, nó không có khả năng phân biệt giữa việc chú ý lặp lại vào một nét phức tạp (cần thiết) và việc chú ý lặp lại do lỗi trôi sự chú ý (cần ngăn chặn).

Hệ quả là mô hình vẫn thường xuyên mắc lỗi lặp lại ký tự (over-parsing) đối với các ký hiệu đa nét (như π, Ξ) hoặc bỏ sót các thành phần nhỏ trong cấu trúc lồng ghép (under-parsing).

5.3.4.2 Nguyên lý hoạt động của Guided Coverage Để khắc phục hạn chế trên, đề án đề xuất chuyển đổi cơ chế bao phủ từ trạng thái thụ động sang trạng thái "chủ động" (explicitly guided). Ý tưởng cốt lõi là sử dụng *Bản đồ Phân bố Không gian* ($\hat{\mathbf{S}}$) và *Bản đồ Quan hệ Cấu trúc* ($\hat{\mathbf{R}}$) dự đoán được từ Encoder để điều chỉnh trọng số (re-weight) cho hình phạt bao phủ.


Cụ thể, thay vì áp dụng một hình phạt đồng đều, mô hình sẽ áp dụng hình phạt mạnh hơn lên các vùng được xác định là quan trọng về mặt không gian hoặc cấu trúc. Công thức tính toán ma trận chú ý tinh chỉnh $\mathbf{A}'_t$ tại bước thời gian t được định nghĩa lại như sau:

$$\mathbf{A}'_{t,i} = \mathbf{A}_{t,i} - \lambda \cdot \underbrace{\left[\mathbf{C}_{t,i} \cdot \left(1 + \alpha \cdot \hat{\mathbf{S}}_i + \beta \cdot \max_k \hat{\mathbf{R}}_{k,i} \right) \right]}_{\text{Guided Penalty Term}} \quad (22)$$

Trong đó:

- $\mathbf{A}_{t,i}$ là điểm chú ý thô (raw attention score) tại vị trí i .
- $\mathbf{C}_{t,i}$ là giá trị bao phủ tích lũy từ các bước trước.
- $\hat{\mathbf{S}}_i$ là xác suất tồn tại nét viết tại vị trí i (từ Spatial Map).

- $\max_k \hat{\mathbf{R}}_{k,i}$ là xác suất cực đại của vị trí i tham gia vào bất kỳ quan hệ cấu trúc nào (từ Relation Map).
- λ, α, β là các hệ số điều tiết siêu tham số.



Hình 4: Kiến trúc Guided ARM đề xuất

5.3.4.3 Trực giác hoạt động và Lợi ích giải mã Cơ chế Guided Coverage hoạt động như một bộ lọc thông minh, tự động điều chỉnh hành vi của Decoder dựa trên ngữ nghĩa của vùng ảnh:

1. **Tại vùng chứa nét viết ($\hat{\mathbf{S}} \approx 1$):** Thành phần $(1 + \alpha \cdot \hat{\mathbf{S}})$ sẽ khuếch đại hình phạt bao phủ. Điều này gửi đi một tín hiệu rõ ràng: *"Vùng này chứa thông tin quan trọng và đã được xử lý, hạn chế việc lặp lại sự chú ý."* Cơ chế này triệt tiêu hiệu quả hiện tượng lặp lại ký tự, đặc biệt hữu ích cho các ký hiệu có cấu trúc rời rạc (ví dụ: dấu bằng =, ký tự i, j).
2. **Tại vùng có cấu trúc phức tạp ($\hat{\mathbf{R}}$ cao):** Các vùng giao thoa giữa nhiều ký tự (như vị trí tiếp giáp giữa tử số và mẫu số) thường gây nhiễu cho cơ chế chú ý. Việc tích hợp thông tin cấu trúc $\hat{\mathbf{R}}$ giúp tăng cường hình phạt tại các điểm nóng này sau khi chúng đã được giải mã, giúp Decoder thoát khỏi các vòng lặp cục bộ trong cấu trúc lồng ghép.
3. **Tại vùng nền ($\hat{\mathbf{S}} \approx 0$):** Hình phạt được giữ ở mức cơ bản ($\approx C_{t,i}$). Điều này cho phép sự chú ý lướt qua các vùng nền một cách nhẹ nhàng mà không bị phạt quá nặng, duy trì tính linh hoạt cần thiết để chuyển đổi sự chú ý giữa các cụm ký tự xa nhau.

5.3.4.4 Tổng kết tác động Thông qua Guided Coverage Attention, các nhiệm vụ phụ trợ không chỉ đóng vai trò huấn luyện Encoder (như một regularizer) mà còn tham gia trực tiếp vào quá trình suy diễn (inference). Sự kết hợp này giải quyết triệt để sự nhập nhằng giữa "nhiều nền" và "nét viết", đồng thời cung cấp một cơ chế định hướng tường minh, giúp quá trình sinh chuỗi LaTeX trở nên ổn định và chính xác hơn, đặc biệt là đối với các biểu thức có độ dài lớn và cấu trúc không gian phức tạp.

5.3.5 Hàm mục tiêu và Chiến lược Huấn luyện Đa nhiệm

Để đảm bảo tính nhất quán và khả năng tối ưu hóa đồng thời các thành phần đã đề xuất, đồ án thiết lập một hàm mục tiêu tổng hợp trong khuôn khổ học đa nhiệm (Multi-task Learning). Mục này trình bày công thức toán học của hàm mất mát và phân tích cơ sở lý luận về sự tương tác giữa các luồng gradient trong quá trình huấn luyện.

5.3.5.1 Hàm mục tiêu tổng quát Bài toán huấn luyện mô hình được định nghĩa là việc tìm kiếm bộ tham số tối ưu θ^* cho toàn bộ mạng nơ-ron nhằm cực tiểu hóa sự sai biệt giữa dự đoán của mô hình và nhãn thực tế trên cả ba khía cạnh: chuỗi ký tự, phân bố không gian và quan hệ cấu trúc. Hàm mục tiêu tổng quát $\mathcal{L}_{total}$ được xây dựng như một tổng có trọng số của ba thành phần mất mát riêng biệt:

$$\mathcal{L}_{total} = \mathcal{L}_{rec} + \lambda_s \cdot \mathcal{L}_{spatial} + \lambda_r \cdot \mathcal{L}_{relation} \quad (23)$$

Trong đó:

- $\mathcal{L}_{rec}$ (Recognition Loss): Là thành phần chủ đạo, chịu trách nhiệm về độ chính xác của chuỗi LaTeX đầu ra.
- $\mathcal{L}_{spatial}$ (Spatial Recovery Loss): Đóng vai trò giám sát khả năng định vị nét viết của Encoder.
- $\mathcal{L}_{relation}$ (Structural Relation Loss): Đóng vai trò giám sát khả năng hiểu cấu trúc hình học của Encoder.
- λ_s, λ_r : Là các siêu tham số (hyper-parameters) dương, dùng để cân bằng độ lớn gradient và điều tiết mức độ đóng góp của các nhiệm vụ phụ trợ vào quá trình cập nhật trọng số.

5.3.5.2 Phân tích vai trò các thành phần mất mát Mỗi thành phần trong hàm mục tiêu đóng một vai trò cụ thể nhưng bổ trợ lẫn nhau trong việc định hình không gian đặc trưng:

- Mất mát Nhận dạng ($\mathcal{L}_{rec}$):** Sử dụng hàm *Cross-Entropy Loss* tiêu chuẩn tính trên xác suất của từng token trong chuỗi dự đoán. Đây là tín hiệu giám sát trực tiếp cho nhiệm vụ chính, đảm bảo mô hình học được cú pháp LaTeX và ngữ nghĩa chuỗi.
- Mất mát Không gian ($\mathcal{L}_{spatial}$):** Sử dụng hàm *Smooth L1 Loss* để đo lường sai số giữa bản đồ phân bố dự đoán $\hat{\mathbf{S}}$ và bản đồ nhãn $\mathbf{S}_{gt}$. Hàm mất mát này ép buộc Encoder phải phân tách rõ ràng các vùng đặc trưng chứa thông tin (foreground) và vùng nhiễu, hoạt động như một bộ lọc sự chú ý ngay từ giai đoạn mã hóa.
- Mất mát Quan hệ ($\mathcal{L}_{relation}$):** Sử dụng hàm *Binary Cross-Entropy Loss* cho bài toán phân loại đa nhãn tại từng điểm ảnh (pixel-wise). Thành phần này đóng vai trò là một bộ điều tiết cấu trúc (structural regularizer), ngăn chặn mô hình học vẹt các mẫu chuỗi mà bỏ qua logic hình học 2D.

5.3.5.3 Cơ chế cộng hưởng trong Huấn luyện Đa nhiệm Việc tối ưu hóa đồng thời ba hàm mất mát tạo ra một cơ chế cộng hưởng tích cực, tác động lên cả Bộ mã hóa (Encoder) và Bộ giải mã (Decoder):

Tác động lên luồng Gradient tại Encoder: Trong quá trình lan truyền ngược (back-propagation), các tham số của Encoder nhận được tổng hợp gradient từ cả ba nhánh.

- Gradient từ $\mathcal{L}_{rec}$ cung cấp thông tin về “ký tự là gì”.
- Gradient từ $\mathcal{L}_{spatial}$ và $\mathcal{L}_{relation}$ cung cấp thông tin về “ký tự ở đâu” và “quan hệ thế nào”.

Sự kết hợp này giúp Encoder học được các biểu diễn đặc trưng (feature representations) mạnh mẽ hơn, vừa có tính phân biệt cao về hình dạng (discriminative), vừa bảo toàn được cấu trúc tô-pô (topology-preserving) của biểu thức gốc.

Tác động gián tiếp lên Decoder: Mặc dù Decoder không trực tiếp chịu sự giám sát của $\mathcal{L}_{spatial}$ và $\mathcal{L}_{relation}$, nhưng nó được hưởng lợi thông qua hai con đường:

- Đặc trưng đầu vào chất lượng cao:** Encoder cung cấp các vector ngữ cảnh sạch nhiễu và giàu cấu trúc hơn.
- Tín hiệu hướng dẫn chính xác:** Việc tối ưu hóa tốt các nhiệm vụ phụ trợ đồng nghĩa

với việc các bản đồ dự đoán $\hat{\mathbf{S}}$ và $\hat{\mathbf{R}}$ ngày càng chính xác. Do đó, tín hiệu điều hướng trong cơ chế *Guided Coverage Attention* (Phần 5.3.4) trở nên đáng tin cậy hơn theo thời gian huấn luyện, giúp Decoder giải mã ổn định và tránh các lỗi lặp lại.

5.4 Dữ liệu đánh giá

Để đảm bảo tính khách quan và khả năng so sánh công bằng với các nghiên cứu trước đây trong lĩnh vực Nhận dạng biểu thức toán học viết tay (HMER), đề án này sử dụng bộ dữ liệu **CROHME** (Competition on Recognition of Handwritten Mathematical Expressions). Đây được coi là chuẩn đánh giá (de facto benchmark) cho các bài toán chuyển đổi hình ảnh sang LaTeX.

5.4.1 Đặc tả dữ liệu

CROHME cung cấp các mẫu dữ liệu dưới dạng cặp (*ảnh đầu vào, chuỗi nhãn LaTeX*). Mặc dù dữ liệu gốc của cuộc thi được thu thập dưới dạng nét mực trực tuyến (online ink traces), trong phạm vi đề án này, chúng tôi sử dụng phiên bản ngoại tuyến (offline) đã được raster hóa thành ảnh tĩnh để phù hợp với kiến trúc mô hình dựa trên Transformer và Computer Vision như CoMER.

Đặc điểm nổi bật của dữ liệu CROHME là sự đa dạng về phong cách viết tay và độ phức tạp cao về cấu trúc không gian. Các biểu thức không chỉ là chuỗi ký tự tuyến tính mà còn bao gồm các cấu trúc 2D lồng ghép như: phân số, căn thức, ma trận, chỉ số trên/dưới. Điều này đặt ra thách thức lớn cho mô hình trong việc giải quyết sự nhập nhằng về ký hiệu và khôi phục mối quan hệ không gian.

Giao thức huấn luyện và kiểm thử

Đề án tuân thủ nghiêm ngặt giao thức phân chia dữ liệu được thiết lập trong baseline CoMER [?] để đảm bảo tính nhất quán trong so sánh kết quả:

- **Tập huấn luyện (Training Set):** Mô hình được huấn luyện trên tập dữ liệu tổng hợp từ các cuộc thi CROHME trước đó (bao gồm CROHME 2011, 2012 và 2013). Việc gộp dữ liệu này nhằm cung cấp cho mô hình khả năng tổng quát hóa tốt hơn đối với các biến thể chữ viết khác nhau.
- **Tập kiểm thử (Test Sets):** Quá trình đánh giá hiệu năng được thực hiện độc lập

trên các tập kiểm thử chuẩn (Test sets) của các năm 2014, 2016 và 2019. Trong đó, tập **CROHME 2014** thường được sử dụng làm tập kiểm chứng (validation) để lựa chọn mô hình tốt nhất trong quá trình huấn luyện, nhằm tránh hiện tượng over-fitting trên tập test chính thức.

Quá trình tiền xử lý ảnh (như chuẩn hóa kích thước, tăng cường dữ liệu) cũng được áp dụng tương đồng với cấu hình chuẩn để đảm bảo mọi sự cải thiện về độ chính xác đều đến từ kiến trúc mô hình đề xuất thay vì sự khác biệt trong xử lý dữ liệu.

5.5 Metrics đánh giá

Để đánh giá hiệu năng của mô hình đề xuất và đảm bảo tính công bằng khi so sánh với baseline CoMER [41] cũng như các phương pháp HMER hiện đại khác, đề án sử dụng độ đo chính là **Expression Recognition Rate (ExpRate)**. Đây là chỉ số tiêu chuẩn được quy định bởi ban tổ chức cuộc thi CROHME và được cộng đồng nghiên cứu chấp nhận rộng rãi.

5.5.1 Expression Recognition Rate (ExpRate)

ExpRate (hay còn gọi là độ chính xác mức biểu thức) được định nghĩa là tỷ lệ phần trăm số lượng biểu thức toán học được nhận dạng chính xác hoàn toàn so với tổng số biểu thức trong tập kiểm thử.

Một biểu thức dự đoán được coi là chính xác nếu và chỉ nếu chuỗi nhãn LaTeX sinh ra **khớp hoàn toàn** (exact match) với chuỗi nhãn LaTeX trong dữ liệu nhãn (Ground Truth). Điều này có nghĩa là mọi thành phần của biểu thức phải đúng, bao gồm:

- **Định danh ký hiệu (Symbol Identity):** Mọi ký tự (số, chữ, toán tử) phải được phân loại đúng.
- **Cấu trúc không gian (Spatial Structure):** Các mối quan hệ không gian (trên, dưới, trong, ngoài, chỉ số mũ, chỉ số dưới) phải được thể hiện chính xác thông qua các token cấu trúc của LaTeX (ví dụ: $\blacksquare$, $_$, $\{ \}$).

Công thức tính ExpRate được biểu diễn như sau:

$$\text{ExpRate} = \frac{N_{\text{correct}}}{N_{\text{total}}} \times 100\% \quad (24)$$

Trong đó:

- N_{correct} : Số lượng biểu thức có chuỗi dự đoán trùng khớp hoàn toàn với nhãn.
- N_{total} : Tổng số biểu thức trong tập dữ liệu đánh giá.

5.5.2 Tính nghiêm ngặt và sự phù hợp

ExpRate là một chỉ số đánh giá có tính nghiêm ngặt rất cao. Khác với các bài toán nhận dạng văn bản thông thường (nơi có thể sử dụng Character Error Rate - CER hay Word Error Rate - WER), trong HMER, chỉ cần một lỗi sai nhỏ về vị trí (ví dụ: nhận dạng x_i thành x_j) hoặc thiếu một cặp ngoặc cấu trúc cũng sẽ khiến toàn bộ biểu thức bị đánh dấu là sai (0 điểm).

Chính vì tính khắt khe này, ExpRate là thước đo phù hợp nhất để kiểm chứng hiệu quả của các module đề xuất trong đồ án, bao gồm *Guided Coverage Attention* và *Structural Relation Prediction*. Các module này được thiết kế để giải quyết các trường hợp nhập nhằng về cấu trúc – nguyên nhân chính dẫn đến việc sụt giảm ExpRate trong các mô hình truyền thống. Việc cải thiện ExpRate sẽ phản ánh trực tiếp năng lực của mô hình trong việc không chỉ nhận dạng đúng ký tự mà còn khôi phục chính xác cấu trúc hình học 2D của biểu thức toán học.

Lưu ý rằng, tuân thủ theo giao thức của CoMER, chúng tôi không sử dụng các metric phụ trợ ở mức ký hiệu (symbol-level accuracy) làm tiêu chuẩn so sánh chính, mà tập trung tối đa vào độ chính xác ở mức toàn cục (global expression level).

5.6 Kết quả thí nghiệm

Để đánh giá hiệu quả của mô hình được tái lập, đồ án tiến hành thực nghiệm trên ba bộ dữ liệu chuẩn: CROHME 2014, CROHME 2016 và CROHME 2019. Quá trình đánh giá sử dụng cùng một quy trình và các thước đo tiêu chuẩn như trong bài báo gốc CoMER, bao gồm:

- **ExpRate (Expression Recognition Rate):** Tỷ lệ nhận dạng chính xác toàn bộ biểu thức. Đây là thước đo quan trọng nhất, được báo cáo ở các mức độ dung sai lỗi (tolerated error) khác nhau ($0, \leq 1, \leq 2, \leq 3$ lỗi).
- **Structure Rate:** Tỷ lệ nhận dạng đúng cấu trúc cây của biểu thức (bỏ qua sai sót về nội dung ký tự).

5.6.1 Kết quả định lượng

Kết quả thực nghiệm của mô hình sau quá trình huấn luyện được trình bày chi tiết trong Bảng ???. Các chỉ số được tính toán bằng công cụ đánh giá chính thức (official scoring scripts) để đảm bảo tính khách quan.

Dataset	Structural Rate	ExpRate (0)	ExpRate (≤ 1)	ExpRate (≤ 2)	ExpRate (≤ 3)
CROHME 2014	69.27%	49.39%	63.49%	68.26%	70.39%
CROHME 2016	71.75%	52.14%	65.30%	70.53%	73.67%
CROHME 2019	72.89%	51.88%	67.39%	72.56%	75.31%

Bảng 4: Kết quả thực nghiệm của mô hình tái lập trên các tập dữ liệu CROHME.

Trên tập CROHME 2014, mô hình đạt ExpRate 49.39% và tỷ lệ nhận dạng cấu trúc đạt xấp xỉ 69.27%. Kết quả này cho thấy mô hình đã học được cách phân giải các cấu trúc không gian 2D phức tạp và nhận diện ký tự với độ chính xác khá. Xu hướng cải thiện hiệu năng được ghi nhận trên các tập dữ liệu sau (2016 và 2019), với ExpRate tăng lên mức 52.14% và Structural Rate đạt tới 72.89%. Đặc biệt, khi nới lỏng điều kiện đánh giá (cho phép sai từ 1 đến 2 lỗi), hiệu năng của mô hình tăng đáng kể (đạt trên 70%), cho thấy phần lớn các lỗi sai chỉ tập trung vào các chi tiết nhỏ cục bộ thay vì sai hỏng toàn bộ cấu trúc.

5.6.2 So sánh với paper CoMER

Bảng ?? trình bày sự so sánh đối chiếu giữa kết quả tái lập trong đề án và kết quả được công bố trong bài báo gốc CoMER (CVPR 2022).

Dataset	Baseline (CoMER)	Mô hình thực nghiệm	Chênh lệch
CROHME 2014	59.33%	49.39%	-9.94%
CROHME 2016	59.81%	52.14%	-7.67%
CROHME 2019	62.97%	51.88%	-11.09%

Bảng 5: So sánh ExpRate (0 lỗi) giữa mô hình thực nghiệm và kết quả gốc từ paper CoMER.

Qua so sánh, có thể thấy kết quả thấp hơn so với báo cáo gốc, với mức chênh lệch dao động khoảng 7% đến 11% tùy vào tập dữ liệu. Mặc dù chưa đạt được có thể so sánh với baseline, nhưng mô hình thực nghiệm vẫn thể hiện được khả năng hội tụ tốt và giải quyết được bài toán HMER ở mức độ chấp nhận được.

5.6.3 Nhận xét

Mô hình hiện tại sử dụng trọng số cố định cho các nhiệm vụ phụ trợ. Trong học đa nhiệm, việc sử dụng trọng số tĩnh thường dẫn đến hiện tượng xung đột gradient (gradient conflict)

hoặc một nhiệm vụ lẫn át nhiệm vụ khác.

Một điểm đáng chú ý là sự chênh lệch lớn giữa $ExpRate$ (0 lỗi) và $ExpRate$ (≤ 1 lỗi) (ví dụ: 51.88% so với 67.39% trên CROHME 2019). Kết hợp với chỉ số $Structural Rate$ đạt mức khả quan ($> 72\%$), điều này chỉ ra rằng:

- Mô hình đã học tốt cấu trúc không gian tổng thể (Global Structure) của biểu thức.
- Phần lớn các lỗi sai thuộc về chi tiết cục bộ (Local Details) như nhầm lẫn ký tự hình dạng giống nhau hoặc sai lệch vị trí chỉ số nhỏ. Đây là các lỗi có thể khắc phục được thông qua tăng cường dữ liệu (Data Augmentation) chuyên biệt hoặc tinh chỉnh (finetuning) dài hơi hơn.

Mặc dù chưa đạt được hiệu năng như bài báo gốc, nhưng mô hình thực nghiệm đã chứng minh được tính đúng đắn trong thiết kế kiến trúc và luồng xử lý. Kết quả hiện tại là nền tảng tin cậy (valid baseline) cho các nghiên cứu cải tiến tiếp theo.

6 Tổng kết

6.1 Đánh giá quá trình thực hiện Đồ án Chuyên ngành

Trong khuôn khổ Đồ án Chuyên ngành, mục tiêu trọng tâm là nghiên cứu và xây dựng nền tảng kỹ thuật cho hệ thống nhận dạng biểu thức toán học viết tay (HMER) sử dụng phương pháp học đa nhiệm. Quá trình thực hiện đã hoàn thành các nội dung công việc đề ra, cụ thể như sau:

Về mặt nghiên cứu và cơ sở lý thuyết

- Đã hệ thống hóa được cơ sở lý thuyết về bài toán HMER, tập trung vào các kiến trúc Transformer và cơ chế Attention.
- Đã phân tích sâu sắc mô hình CoMER (baseline) và xác định được các điểm yếu trong việc mô hình hóa thông tin không gian, từ đó đề xuất hướng tiếp cận sử dụng các tác vụ phụ trợ (Spatial & Structural Awareness).

Về mặt triển khai kỹ thuật và xây dựng hệ thống

Đồ án đã xây dựng thành công một pipeline huấn luyện và đánh giá hoàn chỉnh (End-to-End Pipeline), bao gồm các phân hệ:

- **Module sinh nhãn tự động (Ground-truth Generation):** Đã thiết kế và cài đặt thuật toán tạo Bản đồ phân bố không gian (Spatial Map) và Bản đồ quan hệ cấu trúc (Relation Map) từ chuỗi LaTeX, đảm bảo dữ liệu đầu vào cho quá trình huấn luyện đa nhiệm.
- **Kiến trúc Multi-task Learning:** Đã tích hợp thành công các nhánh dự đoán phụ trợ vào kiến trúc CoMER mà không phá vỡ luồng xử lý chính.
- **Cơ chế Guided Coverage:** Đã hiện thực hóa ý tưởng sử dụng thông tin từ các nhánh phụ trợ để can thiệp vào quá trình tính toán Attention, tạo tiền đề cho việc điều hướng giải mã.

Quá trình thực hiện Đồ án Chuyên ngành đã đạt được mục tiêu "Proof-of-Concept" (Chứng minh khả thi). Hệ thống đã hoạt động ổn định, luồng dữ liệu (data flow) và luồng gradient được kiểm soát tốt. Đây là nền tảng vững chắc (Codebase) để tiến hành các tinh chỉnh chuyên

sâu nhằm tối ưu hóa hiệu năng trong giai đoạn Đề án Tốt nghiệp.


6.2 Hướng phát triển và kế hoạch thực hiện giai đoạn Đề án Tốt nghiệp

Dựa trên nền tảng đã xây dựng, giai đoạn Đề án Tốt nghiệp sẽ tập trung vào việc giải quyết các điểm nghẽn kỹ thuật để chuyển đổi từ một mô hình "chạy được" sang một mô hình "hiệu năng cao".

6.3 Hướng phát triển

Mặc dù kết quả hiện tại chưa vượt qua baseline, hướng tiếp cận sử dụng thông tin không gian và cấu trúc (Spatial & Structural Awareness) vẫn được đánh giá là tiềm năng, phù hợp với xu hướng nghiên cứu hiện nay (như SSAN [35], MMHMER [5]). Để khắc phục các hạn chế nêu trên, các hướng cải tiến sau được đề xuất:

1. **Tái thiết kế các Module Dự đoán (Auxiliary Heads):** Thay thế các lớp Convolution đơn giản bằng các kiến trúc mạnh hơn vì các nhiệm vụ phụ trợ chưa hội tụ ổn định (Hình 5), cho thấy kiến trúc dự đoán hiện tại chưa đủ khả năng biểu diễn các ràng buộc không gian và cấu trúc.
2. **Cải tiến Cơ chế Guided Coverage:** Nghiên cứu các phương pháp tích hợp thông tin bản đồ vào quá trình giải mã (Decoding) một cách mềm dẻo hơn, thay vì can thiệp cứng vào Attention Score.



Hình 5: Validation loss của các nhiệm vụ bổ trợ

6.4 Kế hoạch thực hiện giai đoạn Đồ án Tốt nghiệp

Dựa trên các phân tích và hướng phát triển đã xác định, kế hoạch thực hiện cho giai đoạn Đồ án Tốt nghiệp được dự kiến như sau:

Giai đoạn	Thời gian	Nội dung công việc
1	Tuần 1 - 3	Nghiên cứu & Tái thiết kế kiến trúc: - Tìm hiểu sâu các kiến trúc Segmentation Head (U-Net, FPN). - Cài đặt lại Spatial Head và Relation Head.
2	Tuần 4 - 6	Thực nghiệm Ablation Study: - Thử nghiệm các chiến lược cân bằng loss (Uncertainty Weighting). - Đánh giá tác động riêng lẻ của từng tác vụ phụ trợ.
3	Tuần 7 - 10	Huấn luyện & Tối ưu hóa: - Huấn luyện toàn diện trên CROHME với các cấu hình tốt nhất. - Fine-tuning siêu tham số để tối đa hóa ExpRate.
4	Tuần 11 - 12	Viết báo cáo & Bảo vệ: - Tổng hợp kết quả, so sánh chi tiết với CoMER và các phương pháp SOTA khác. - Hoàn thiện báo cáo Đồ án Tốt nghiệp.

Bảng 6: Dự kiến kế hoạch thực hiện Đồ án Tốt nghiệp.

References

- [1] Robert H. Anderson. Syntax-directed recognition of hand-printed two-dimensional mathematics. In *Symposium on Interactive Systems for Experimental Applied Mathematics: Proceedings of the Association for Computing Machinery Inc. Symposium*, page 436–459, New York, NY, USA, 1967. Association for Computing Machinery.
- [2] Xiaohang Bian, Bo Qin, Xiaozhe Xin, Jianwu Li, Xuefeng Su, and Yanfeng Wang. Handwritten mathematical expression recognition via attention aggregation based bi-directional mutual learning. *Proceedings of the AAAI Conference on Artificial Intelligence*, 36:113–121, 06 2022.
- [3] Kam-Fai Chan and Dit-Yan Yeung. Error detection, error correction and performance evaluation in on-line mathematical expression recognition. *Pattern Recognition*, 34(8):1671–1684, 2001.
- [4] Kam-fai Chan and Dit-Yan Yeung. Mathematical expression recognition: A survey. *International Journal on Document Analysis and Recognition*, 3, 02 2001.
- [5] Kehua Chen, Haoyang Shen, Lifan Zhong, and Mingyi Chen. Mmhmer:multi-viewer and multi-task for handwritten mathematical expression recognition, 2025.
- [6] Zhanzhan Cheng, Fan Bai, Yunlu Xu, Gang Zheng, Shiliang Pu, and Shuigeng Zhou. Focusing attention: Towards accurate text recognition in natural images. *CoRR*, abs/1709.02054, 2017.
- [7] Haisong Ding, Kai Chen, and Qiang Huo. An encoder-decoder approach to handwritten mathematical expression recognition with multi-head attention and stacked decoder. In *Document Analysis and Recognition – ICDAR 2021: 16th International Conference, Lausanne, Switzerland, September 5–10, 2021, Proceedings, Part II*, page 602–616, Berlin, Heidelberg, 2021. Springer-Verlag.
- [8] Philippe Gervais, Anastasiia Fadeeva, and Andrii Maksai. Mathwriting: A dataset for handwritten mathematical expression recognition, 2025.
- [9] Xavier Glorot, Antoine Bordes, and Yoshua Bengio. Deep sparse rectifier neural networks. In Geoffrey Gordon, David Dunson, and Miroslav Dudík, editors, *Proceedings of the Fourteenth International Conference on Artificial Intelligence and Statistics*, volume 15

of *Proceedings of Machine Learning Research*, pages 315–323, Fort Lauderdale, FL, USA, 11–13 Apr 2011. PMLR.

- [10] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition, 2015.
- [11] Gao Huang, Zhuang Liu, Laurens van der Maaten, and Kilian Q. Weinberger. Densely connected convolutional networks, 2018.
- [12] Sergey Ioffe and Christian Szegedy. Batch normalization: Accelerating deep network training by reducing internal covariate shift, 2015.
- [13] Stephane Lavirotte and Loic Pottier. Mathematical formula recognition using graph grammar. *Proc SPIE*, 3305:44–52, 04 1998.
- [14] Bohan Li, Ye Yuan, Dingkan Liang, Xiao Liu, Zhilong Ji, Jinfeng Bai, Wenyu Liu, and Xiang Bai. When counting meets hmer: Counting-aware network for handwritten mathematical expression recognition. In *Proceedings of the European Conference on Computer Vision (ECCV)*, pages 197–214, 2022.
- [15] Bohan Li, Ye Yuan, Dingkan Liang, Xiao Liu, Zhilong Ji, Jinfeng Bai, Wenyu Liu, and Xiang Bai. When counting meets hmer: Counting-aware network for handwritten mathematical expression recognition, 2022.
- [16] Junnan Li, Dongxu Li, Silvio Savarese, and Steven Hoi. Blip-2: Bootstrapping language-image pre-training with frozen image encoders and large language models, 2023.
- [17] Yu Li, Jin Jiang, Jianhua Zhu, Shuai Peng, Baole Wei, Yuxuan Zhou, and Liangcai Gao. Uni-mumer: Unified multi-task fine-tuning of vision-language model for handwritten mathematical expression recognition, 2025.
- [18] Zhe Li, Lianwen Jin, Songxuan Lai, and Yecheng Zhu. Improving attention-based handwritten mathematical expression recognition with scale augmentation and drop attention, 2020.
- [19] Chenyu Liu, Jia Pan, Jinshui Hu, Baocai Yin, Bing Yin, Mingjun Chen, Cong Liu, Jun Du, and Qingfeng Liu. Namer: Non-autoregressive modeling for handwritten mathematical expression recognition, 2024.

- [20] Scott Maclean and George Labahn. A new approach for recognizing handwritten mathematics using relational grammars and fuzzy sets. *International Journal on Document Analysis and Recognition (IJDAR)*, 16, 06 2012.
- [21] Scott MacLean and George Labahn. A bayesian model for recognizing handwritten mathematical expressions. *Pattern Recognition*, 48(8):2433–2445, 2015.
- [22] H. Mouchère, C. Viard-Gaudin, R. Zanibbi, and U. Garain. Icfhr 2014 competition on recognition of on-line handwritten mathematical expressions (crohme 2014). In *2014 14th International Conference on Frontiers in Handwriting Recognition*, pages 791–796, Sep. 2014.
- [23] Harold Mouchère, Christian Viard-Gaudin, Richard Zanibbi, and Utpal Garain. Icfhr 2014 competition on recognition of on-line handwritten mathematical expressions (crohme 2014). volume 2014, 09 2014.
- [24] Alec Radford, Jeff Wu, Rewon Child, David Luan, Dario Amodei, and Ilya Sutskever. Language models are unsupervised multitask learners. 2019.
- [25] Karen Simonyan and Andrew Zisserman. Very deep convolutional networks for large-scale image recognition, 2015.
- [26] Thanh-Nghia Truong, Cuong Tuan Nguyen, Khanh Minh Phan, and Masaki Nakagawa. Improvement of end-to-end offline handwritten mathematical expression recognition by weakly supervised learning. In *2020 17th International Conference on Frontiers in Handwriting Recognition (ICFHR)*, pages 181–186, Sep. 2020.
- [27] Zhaopeng Tu, Zhengdong Lu, Yang Liu, Xiaohua Liu, and Hang Li. Modeling coverage for neural machine translation, 2016.
- [28] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. Attention is all you need, 2023.
- [29] Changjie Wu, Jun Du, Yunqing Li, Jianshu Zhang, Chen Yang, Bo Ren, and Yiqing Hu. Tdv2: A novel tree-structured decoder for offline mathematical expression recognition. *Proceedings of the AAAI Conference on Artificial Intelligence*, 36:2694–2702, 06 2022.

- [30] Jin-Wen Wu, Fei Yin, Yan-Ming Zhang, Xu-Yao Zhang, and Cheng-Lin Liu. Handwritten mathematical expression recognition via paired adversarial learning. *International Journal of Computer Vision*, 128, 11 2020.
- [31] Yejing Xie, Harold Mouchère, Foteini Liwicki, Sumit Rakesh, Rajkumar Saini, Masaki Nakagawa, Cuong Nguyen, and Thanh-Nghia Truong. *ICDAR 2023 CROHME: Competition on Recognition of Handwritten Mathematical Expressions*, pages 553–565. 08 2023.
- [32] Kelvin Xu, Jimmy Ba, Ryan Kiros, Kyunghyun Cho, Aaron Courville, Ruslan Salakhutdinov, Richard Zemel, and Yoshua Bengio. Show, attend and tell: Neural image caption generation with visual attention, 2016.
- [33] Ryo Yamamoto, Shinji Sako, Takuya Nishimoto, and Shigeki Sagayama. On-Line Recognition of Handwritten Mathematical Expressions Based on Stroke-Based Stochastic Context-Free Grammar. In Guy Lorette, editor, *Tenth International Workshop on Frontiers in Handwriting Recognition*, La Baule (France), October 2006. Université de Rennes 1, Suvisoft. <http://www.suvisoft.com>.
- [34] Ye Yuan, Xiao Liu, Wondimu Dikubab, Hui Liu, Zhilong Ji, Zhongqin Wu, and Xiang Bai. Syntax-aware network for handwritten mathematical expression recognition. *arXiv preprint arXiv:2203.01601*, 2022.
- [35] Haoran Zhang, Xiangdong Su, Xingxiang Zhou, and Guanglai Gao. Ssan: A symbol spatial-aware network for handwritten mathematical expression recognition. *Proceedings of the AAAI Conference on Artificial Intelligence*, 39(21):22398–22406, Apr. 2025.
- [36] Jianshu Zhang, Jun Du, and Lirong Dai. Multi-scale attention with dense encoder for handwritten mathematical expression recognition, 2018.
- [37] Jianshu Zhang, Jun Du, and Lirong Dai. Multi-scale attention with dense encoder for handwritten mathematical expression recognition. In *International Conference on Pattern Recognition*, pages 2245–2250, 2018.
- [38] Jianshu Zhang, Jun Du, Yongxin Yang, Yi-Zhe Song, Si Wei, and Lirong Dai. A tree-structured decoder for image-to-markup generation. In Hal Daumé III and Aarti Singh, editors, *Proceedings of the 37th International Conference on Machine Learning*, volume 119 of *Proceedings of Machine Learning Research*, pages 11076–11085. PMLR, 13–18 Jul 2020.

- [39] Jianshu Zhang, Jun Du, Shiliang Zhang, Dan Liu, Yulong Hu, Jinshui Hu, Si Wei, and Lirong Dai. Watch, attend and parse: An end-to-end neural network based approach to handwritten mathematical expression recognition. *Pattern Recognition*, 71:196–206, 2017.
- [40] Xinyu Zhang, Han Ying, Ye Tao, Youlu Xing, and Guihuan Feng. General category network: Handwritten mathematical expression recognition with coarse-grained recognition task. In *ICASSP 2023 - 2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pages 1–5, June 2023.
- [41] Wenqi Zhao and Liangcai Gao. Comer: Modeling coverage for transformer-based handwritten mathematical expression recognition. In Shai Avidan, Gabriel Brostow, Moustapha Cissé, Giovanni Maria Farinella, and Tal Hassner, editors, *Computer Vision – ECCV 2022*, pages 392–408, Cham, 2022. Springer Nature Switzerland.
- [42] Wenqi Zhao, Liangcai Gao, Zuoyu Yan, Shuai Peng, Lin Du, and Ziyin Zhang. Handwritten mathematical expression recognition with bidirectionally trained transformer, 2021.
- [43] Jianhua Zhu, Liangcai Gao, and Wenqi Zhao. *ICAL: Implicit Character-Aided Learning for Enhanced Handwritten Mathematical Expression Recognition*, page 21–37. Springer Nature Switzerland, 2024.
- [44] Jianhua Zhu, Wenqi Zhao, Yu Li, Xingjian Hu, and Liangcai Gao. Tamer: Tree-aware transformer for handwritten mathematical expression recognition, 2024.
- [45] Francisco Álvaro, Joan-Andreu Sánchez, and José-Miguel Benedí. An integrated grammar-based approach for mathematical expression recognition. *Pattern Recognition*, 51:135–147, 2016.